

用于高保真水下场景重建的语义引导高斯点投影

蒋卓东^{a,*}, 王浩然^{a,1}, 黄国熙^a, 布雷特·西摩尔^b 和 南蒂拉·阿南特拉斯里查伊^a

^aSchool of Computer Science, University of Bristol, Bristol, UK

^bSubmerged Resources Centre, Denver, CO, USA

文章信息

Keywords 3D 重建 高斯点撒语义
感知 3D 重建 水下场景重建

摘要

在退化成像条件下实现精确的3D重建仍然是摄影测量和神经渲染中的一个关键挑战。在水下环境中，由于散射、衰减和稀疏观测造成的空间可见性变化会导致信息质量高度不均匀。现有的3D高斯点扩散（3DGS）方法通常仅基于光度信号优化原语，从而导致表示不平衡，在观测良好的区域出现过拟合，而在退化区域重建不足。在本文中，我们提出了SWAGSplattng（语义引导的水下场景增强高斯点扩散），这是一个多模态框架，将语义先验整合到3DGS中，以实现稳健、高保真的水下重建。每个高斯原语都增强了可学习的语义特征，由基于CLIP的嵌入监督，这些嵌入源自区域级提示。引入语义一致性损失以将几何重建与高级语义对齐，...

1. 引言

水下探测支持广泛的应用，包括机器人学、考古学和海洋生态学，这些应用都依赖于准确的三维重建来进行可视化、解释和导航。主动感知方式，如声纳和激光雷达，提供直接的距离测量，但在水下的应用受限于分辨率、成本和操作复杂性（Sun, Cui 和 Chen, 2021）。声学传感器能够实现远距离感知，但通常产生低分辨率的重建，而水下激光雷达则受到强衰减和散射的影响，从而限制了有效范围。相比之下，基于图像的方法依赖被动感知和广泛可用的摄像系统，成本较低且提供更高的空间分辨率以实现精细重建。这些优势使其特别具有吸引力；然而，水下环境也存在独特的挑战，如能见度有限、颜色失真、视点稀疏、海雪以及噪声。

分布不均，进一步加大了在这种条件下进行可靠三维重建的难度。

基于摄影测量的方法长期以来一直构成三维场景重建的基础，包括水下环境（Elnashef 和 Filin, 2023; Zhong, Li, Gruen, Schindler, Liao 和 Guo, 2025）。这些方法通过多视图图像对应关系和相机标定来恢复几何信息，通常通过如运动恢复结构（Structure-from-Motion, SfM）和多视图立体（Multi-View Stereo, MVS）等流程，在良好的成像条件下估计相机姿态和密集表面几何。然而，在低纹理、散射和非均匀光照等具有挑战性的场景中，其性能会下降，此时可靠的特征匹配和深度估计变得困难（Song, She 和 Köser, 2024）。此外，这些流程可能计算量大，限制了其在大规模或时间敏感环境中的适用性。

神经渲染的最新进展通过新颖视图合成（NVS）引入了用于三维重建的替代范式。神经辐射场（NeRF）（Mildenhall, Srinivasan, Tancik, Barron, Ramamoorthi 和 Ng, 2021）通过建模连续体积表示实现高质量的重建，但需要密集的输入视图并且计算成本高。最近，三维高斯点（3DGS）（Kerbl, Kopanas, Leimkühler 和 Drettakis, 2023）作为一种高效的显式表示出现，能够实现更快的优化和实时渲染。尽管具有这些优势，大多数基于 NeRF 和 3DGS 的方法假设成像条件清晰，并且表现出显著的性能下降。

*Corresponding author

✉ zhuodong.jiang@bristol.ac.uk (Z. Jiang); yp22378@bristol.ac.uk (H. Wang); guoxi.huang@bristol.ac.uk (G. Huang); Brett_Seymour@nps.gov (B. Seymour); n.anantrasirichai@bristol.ac.uk (N. Anantrasirichai)
ORCID(s): 0009-0002-5000-2752 (Z. Jiang); 0000-0002-2122-5781 (N. Anantrasirichai)

¹Equal contribution

在混浊的水下环境中。已经提出了几种整合水下图像退化模型的方法 (Levy、Peleg、Pearl、Rosenbaum、Akkaynak、Korman 和 Treibitz, 2023; Wang、Anantrasirichai、Zhang 和 Bull, 2025; Li、Song、Xu、Elsig 和 Kulhanek, 2025; Jiang、Wang、Huang、Seymour 和 Anantrasirichai, 2025)，这些方法在三维重建中显示出有希望的改进，但仍存在一个关键限制：这些方法在优化过程中对所有场景区域一视同仁。

在水下环境中，视觉信息在空间上是不均匀的。前景物体通常提供比受散射和衰减影响的背景区域更强且更可靠的信号。没有明确指导时，标准优化过程会优先处理观测良好的区域，从而削弱了语义重要或退化区域的贡献。这会导致重建结果中显著结构显得模糊或几何上不一致。一个相关的限制来自梯度驱动的高斯稠密化，它根据光度信号强度分配基本元素。在退化的成像条件下，这会导致基本元素分布不平衡，其中观测良好的区域积累了多余的高斯元素，而困难区域仍被低估，从而最终限制了重建的精确度。

为了解决这些限制，我们提出了一种用于水下三维重建的语义增强高斯点投射框架，SWAGSplatting（语义引导水下场景增强高斯点投射）。该方法将语义先验与物理基础建模结合，以在复杂成像条件下提高重建效果。具体而言，从视觉-语言模型（如 CLIP (Radford, Kim, Hallacy, Ramesh 等, 2021)）中获得的语义线索用于提供补充光度监督的高级上下文信息。CLIP 从大规模图像-文本数据中学习可迁移的视觉-语义对应关系，使其能够在无需任务特定训练的情况下实现跨域泛化。我们通过语义一致性损失引入这些信息，该损失作为辅助正则项，用于将每个高斯点的语义特征与区域级语义嵌入对齐。重要的是，该正则化在特征空间中运行，并

此外，标准的 3DGS 依赖于梯度驱动的稠密化，根据光度信号强度分配基元。在退化的成像条件下，这会导致高斯分布不平衡，观测良好的区域主导优化过程，而低可见度区域则代表性不足。因此，表示能力的利用效率低，在高信号区域存在冗余基元，而在困难区域覆盖不足，最终限制了重建质量。为了解决这一限制，我们提出了一种自适应高斯分配策略，用于重新分配




图1: 3DGS (Kerbl 等, 2023)、UW-GS (Wang 等, 2025) 与所提出的 SWAGSplatting (我们的) 重建性能比较。与 3DGS 和 UW-GS 方法相比，SWAGSplatting 明显抑制了伪影生成，并产生了更真实的渲染结果。

基于重建难度的表示能力，实现更均衡的空间覆盖和更高的重建保真度，如图 1 所示。

本工作的主要贡献如下：

- 我们提出了一种用于水下场景重建的语义引导3D高斯投影框架，其中每个高斯原语都增强了从视觉-语言嵌入中获得的可学习语义特征，从而实现面向对象和语义一致的重建。
- 我们引入了一种语义引导的损失，它强制语义表示与几何表示之间的对齐，从而在退化的成像条件下提高结构一致性并保留显著物体边界。
- 提出自适应高斯基元重新分配，通过将低重要性的基元重新分配到高误差区域，以平衡高斯点云的分布，从而提高NVS的质量。
- 我们提出了一种分阶段优化策略，这是一种从粗到细的训练方案，通过后期阶段参数冻结和 ℓ_2 微调来增强稳定性和视觉质量。

我们对 SeaThru-NeRF (Levy 等, 2023)、Submerged3D (Jiang 等, 2025) 和 S-UW (Wang 等, 2025) 数据集进行了全面评估，结果显示在 PSNR 上最多提升了 3.48 dB，并且在 SSIM 和 LPIPS 上相较于最先进的基线方法均有稳定提升。

2. 相关工作

在神经渲染兴起之前，水下三维重建主要依赖于基于结构光重建(SfM)和多视图立体(MVS)构建的摄影测量管线。诸如COLMAP (Schonberger和Frahm, 2016) 这样的系统从图像间的特征对应关系中提取稀疏点云，然后通过立体匹配使其密集化。

匹配，构成了许多水下勘测工作流（Bryson, Johnson-Roberson, Pizarro 和 Williams, 2016）以及商业软件（Burns 和 Delparte, 2017）的骨干。然而，这些方法假设表面为朗伯表面且光照一致，而水下环境很少满足这些条件，在水下散射、背向散射和波长依赖的衰减会破坏特征检测和立体匹配。通常会应用诸如直方图均衡、暗通道先验去雾或Sea-thru颜色校正（Akkaynak 和 Treibitz, 2019）等预处理步骤来改善输入质量，但它们无法完全补偿严重衰减，尤其是在深水或浑浊水中。声学传感提供了一种互补方法。这包括多波束声纳和结构光系统，它们可以独立于光学条件恢复几何信息，但生成的重建结果稀疏或缺乏纹理（Hu, Wang, Shen, Weng, Zhou, Xia 和 Weng, 2023）。

近来的经典方法已经探索了立体视觉和同步定位与建图（SLAM）用于实时水下重建。基于立体的系统利用对极几何恢复密集深度图，并采用考虑壳体界面折射失真的水下专用校准模型（Treibitz, Schechner, Kunz 和 Singh, 2012; She, Nakath, Song 和 Köser, 2022）。为水下使用而改编的视觉 SLAM 系统，如整合惯性测量或声纳约束的系统，使机器人在移动过程中能够增量构建地图（Heshmat, Saad Saoud, Abujabal, Sultan, Elmezain, Seneviratne 和 Hussain, 2025）。虽然这些方法非常适合在线导航任务，但它们通常生成的重建精度低于离线神经渲染流程，并且在面对动态光照和介质散射引起的外观不一致时表现不佳。摄影测量和基于 SLAM 方法的局限性

2.1. 基于 NeRF 的水下场景重建

NeRF（Mildenhall 等, 2021）在散射介质中的扩展引起了越来越多的关注，这主要是由于需要将场景几何与介质引起的衰减分离。早期的工作如 ScatterNeRF（Ramazzina, Bijelic, Walz, Sanvito, Scheuble 和 Heide, 2023）明确地将体积衰减与物体几何分开建模，为参与介质中的渲染提供了一个物理基础的公式。

在（Akkaynak 和 Treibitz, 2018）修订的水下图像形成模型的基础上，SeaThru-NeRF（Levy 等, 2023）引入了专门的网络组件来独立建模透射率和媒介颜色，从而实现场景外观与水体影响的更好解耦。随后的工作集中于在这一框架下提高重建质量。例如，SP-SeaNeRF（Chen, Xiong, Zhang, Yu, Fang）

刘等人（2024）引入了可学习的光照嵌入，以提高图像的清晰度和细节保留。另一类研究通过物理驱动模型来解决颜色退化问题。WaterNeRF（Sethuraman, Ramagopal 和 Skinner, 2023）将光传输建模与最优传输相结合进行颜色校正，而 WaterHE-NeRF（Zhou, Liang, Zhang, Liu, Wang 和 Wu, 2025）采用基于 Retinex 的方法来补偿与波长相关的衰减。这些方法强调了准确的颜色建模对于感知一致重建的重要性。

在水下环境中处理动态元素仍然是一个关键挑战。UWNeRF（Tang, Zhu, Wan, Xu 和 Shi, 2024）通过分离静态和动态区域来提高重建的稳定性，尽管它依赖于准确的掩膜。AquaNeRF（Gough, Azzarelli, Zhang 和 Anantrasirichai, 2025）使用单射线路径表面形式和高斯加权透射率来缓解动态伪影，从而减少了对显式分割的依赖。

尽管有这些进展，基于 NeRF 的方法仍然受制于对密集输入视图的依赖、高计算成本以及有限的渲染效率。这些限制促使我们采用更高效的显式表示方法，例如 3DGS，我们将在接下来的内容中讨论。

2.2. 基于3DGS的水下场景重建

最近在三维高斯点喷射（3DGS）方面的进展（Kerbl 等, 2023）使得通过显式的基于点的表示实现高效且高质量的场景重建成为可能。与基于 NeRF 的方法相比，3DGS 提供了更快的训练速度和实时渲染能力，使其在大规模和交互式应用中具有吸引力。然而，由于散射、衰减以及动态扰动（Huang, Wang, Seymour, Kovacs, Ellerbrock, Blackham 和 Anantrasirichai, 2025c），将 3DGS 直接应用于水下环境仍然具有挑战性。

3DGS 在水下场景的早期适应主要集中在引入光传播的物理模型。UW-GS（Wang 等, 2025）引入了一个物理感知密度控制机制、伪深度监督和运动掩码，以抑制散射和动态干扰的影响。WaterSplatting（Li 等, 2025）通过显式建模物体和介质的透射率来提高逼真度，从而在不同水下条件下实现更高的视觉质量。Aquatic-GS（Liu, Lu, Gu, Li 和 Deng, 2024）将隐式水下表示与显式高斯基元相结合，以实现物理一致的重建。

后续的研究探讨了多种策略，以提高神经渲染方法在水下环境中的鲁棒性，在这些环境中，可见度下降和光照变化普遍存在。例如，Sea-Splat（Yang, Leonard 和 Girdhar, 2025）将水下图像形成模型引入 3DGS 框架中，以将场景辐射与介质效应解耦，从而增强颜色逼真度和几何重建效果。

然而，该方法主要针对静态场景，可能在更复杂或动态的环境中效果较差。RecGS (Zhang, Zhi, Meyers, Durant 等, 2025) 采用一种递归优化策略，逐步完善重建，以抑制水引起的伪影，从而在视觉条件较差时提高稳定性。RUSplatting (Jiang 等, 2025) 进一步引入了一种不确定性感知建模机制，用于估计观测的可靠性，并在优化过程中减少噪声或损坏输入的影响。同时，R-Splatting (Huang, Wang, Qi, Lu, Bull 和 Anantrasirichai, 2025b) 整合了预训练的图像增强网络，以缓解照明衰减和色彩失真，这在浅水场景中尤为明显。

另一个方向集中于结构分解和表示设计。AtlantisGS (Yi, Bi, Zheng, Huang, Zhan 等, 2025) 将前景物体与背景介质分离，并为显著区域配置额外的基元，从而在稀疏视角设置中提高重建质量。这些方法强调了在考虑场景结构和环境效应时调整高斯表示的重要性。

现有的方法主要集中在低级图像恢复或观测加权上，并且常常忽视了可以在空间可见性变化下进一步稳定重建的更高级结构或语义线索。这一局限性促使开发结合额外先验以指导复杂水下环境中几何优化的方法。

3. 初步事项

3.1. 3D 高斯点撒 (3DGS)

3D 高斯点撒 (3DGS) (Kerbl 等, 2023) 将场景表示为一组显式原语，形式为各向异性 3D 高斯分布。每个高斯 G_i 由其均值位置 $\mu_i \in \mathbb{R}^3$ 、协方差矩阵 $\Sigma_i \in \mathbb{R}^{3 \times 3}$ 、不透明度 α_i (或密度贡献) 以及视角依赖的颜色 c_i 参数化。协方差矩阵编码每个原语的空间范围和方向，使各向异性高斯能够比各向同性表示更有效地近似局部表面几何。

在渲染过程中，每个高斯函数都使用相机投影模型从三维空间投影到二维图像平面上。设 $\mathbf{x}$ 表示图像空间中的一个像素位置。投影高斯函数对 $\mathbf{x}$ 的贡献被建模为二维高斯分布：

$$G_i(\mathbf{x}) = \exp\left(-\frac{1}{2}(\mathbf{x} - \mu_i)^\top \Sigma_i^{-1}(\mathbf{x} - \mu_i)\right), \quad (1)$$

其中 μ_i 和 Σ_i 表示在屏幕空间中的投影均值和协方差。该公式通过在图像空间中评估每个高斯的影响，实现了高效的光栅化。为了便于可微分优化，协方差矩阵 Σ_i 在三维高斯原语中被分解为旋转矩阵 $R_i \in \mathbb{R}^{3 \times 3}$ 和缩放矩阵 $S_i \in \mathbb{R}^{3 \times 3}$ 。

$$\Sigma_i = R_i S_i S_i^T R_i^T. \quad (2)$$

为了考虑可见性和遮挡，使用从前到后的 Alpha 混合将高斯函数进行合成。像素 $\mathbf{x}$ 的最终颜色由以下公式给出：

$$C(\mathbf{x}) = \sum_{i=1}^N \alpha_i c_i(\mathbf{v}) \prod_{j=1}^{i-1} (1 - \alpha_j), \quad (3)$$

其中 $\mathbf{v}$ 表示观察方向，而 $c_i(\mathbf{v})$ 通常使用球面谐波 (SH) 表示，以建模视图相关的外观。乘法项考虑了沿光线的累积透射率，以确保正确的可见性顺序。

高斯的参数，包括位置、协方差、颜色和不透明度，通过基于梯度的优化方法最小化渲染图像与观测图像之间的光度重建损失来优化。为了提高场景覆盖率，3DGS 采用了一种自适应增密策略，在重建梯度较高的区域引入额外的高斯 (Huang, Liu 和 Wong, 2025a)。虽然在观测良好的区域效果显著，但这种基于梯度的分配在非均匀成像条件下可能导致原始元素分布不平衡 (Wang, Huang, Zhang, Bull 和 Anantrasirichai, 2026)，这是我们在本工作中所要解决的一个限制。

3.2. 水下图像形成

水下图像的形成由光与周围介质的相互作用决定，导致其退化程度比空气中成像显著更强。具体来说，光的传播受到依赖波长的吸收和散射的影响，这导致对比度降低、颜色失真以及空间上可见性变化 (Tang 等, 2024)。这些效应对基于图像的三维重建构成了重大挑战，因为它们违反了外观一致性和可靠特征对应的常见假设。

根据广泛采用的水下成像模型 (Akkaynak 和 Treibitz, 2018)，相机像素处观察到的颜色 I_c 可以表示为衰减的直接信号和后向散射光的组合：

$$I_c = J \cdot T^D + B^\infty \cdot (1 - T^B), \quad (4)$$

其中 J 表示真实的场景辐射， B^∞ 表示由介质贡献的背景光。传输项 T^D 和 T^B 分别对应直接和后向散射分量，其建模如下：

$$\begin{aligned} T^D &= \exp(-\beta^d \cdot z), \\ T^B &= \exp(-\beta^b \cdot z), \end{aligned} \quad (5)$$

其中 β^d 和 β^b 是衰减系数， z 表示场景点与相机之间的距离。

直接传输项 T^D 模拟了沿视线由于吸收和散射而导致的场景辐射的指数衰减，随着深度增加导致对比度逐渐丧失。反向散射




图2：所提框架的流程。黄色高亮部分表示关键组件：（1）用于面向对象正则化的语义引导损失 L_s ；（2）自适应高斯基元重新分配，以在固定基元预算下改善表示平衡；（3）分阶段优化，用于稳定训练和提高重建保真度。

组件 T^B 考虑了悬浮粒子向相机散射的光，产生了减弱图像清晰度并模糊细微结构细节的遮蔽效应（Bekerman, Avidan 和 Treibitz, 2020）。这些效应还因波长依赖的衰减而进一步加剧，其中较短波长（例如蓝色）传播距离比较长波长（例如红色）更远，从而导致水下图像出现特征性的颜色变化。

从重建的角度来看，这些物理过程导致了若干挑战。首先，衰减会降低远处区域的信噪比，使特征检测和匹配不可靠。其次，后向散射引入了空间变化的雾霾，削弱了视图间的几何一致性。第三，对深度的依赖产生了场景中非均匀的可见性，使不同区域的观测精度各不相同。因此，标准的重建方法倾向于优先处理观测良好的区域，而对退化区域的表示不足。在3D生成重建（3DGS）的背景下，考虑这些物理因素对于在水下条件下实现均衡表示和稳健重建至关重要。

4. 方法论

整体框架如图2所示，其中新增组件以黄色突出显示。每个高斯原语都扩展了一个可学习的语义特征向量，该向量与从CLIP导出的嵌入对齐，以融合高级上下文信息。区域级分割上定义的语义一致性损失 L_s ，

提供辅助监督，以促进对象级一致性并减少冗余背景区域的影响。为了解决表示不平衡问题，引入了一种自适应高斯分配机制，将低贡献区域的基本单元重新分配到重建误差较高的区域。此过程在保持固定基本单元数量的同时，提高了空间覆盖率和重建精度。此外，采用分阶段优化策略以提高训练稳定性。优化从专注于全局结构的初始阶段开始，逐步进入强调细粒度外观的精细化阶段，使在退化成像条件下的重建更加一致。该框架还结合了我们之前工作（Jiang et al., 2025）中的帧插值策略，该策略已被证明能在稀疏视角场景中提升性能。

4.1. 语义引导高斯

传统的3D高斯点撒（Gaussian Splatting）通过光度重建损失对所有基元进行统一优化，而不考虑信息内容的空间变化。在水下环境中，这一假设并不理想，因为由于散射、衰减和稀疏观测，视觉质量高度不均匀。因此，显著的前景结构需要更高的重建精度，而退化区域提供的信号弱且不可靠，阻碍几何一致性。




图3: 所提语义引导高斯模块的概览。BLIP3-o 和 Grounded-SAM 用于提取语义区域, 从这些区域中提取基于 CLIP 的特征, 以监督相应高斯原语的可学习语义特征。

为了解决这一限制, 我们将语义信息融入高斯表示中, 以实现面向对象的正则化。所提出的语义引导高斯模块概述如图3所示。通过整合语义特征, 该框架将高层场景理解与低层退化联系起来。在浑浊条件下, 仅靠光度监督难以区分真实几何与介质引起的伪影, 例如反向散射。所提出的语义引导损失 (L_s) 通过在相同语义区域 (例如珊瑚礁或沉船) 内强制高斯基元的特征一致性, 作为一种结构约束。这样可以避免在语义不一致的区域 (如漂浮颗粒或雾霾) 分配密度, 从而提高重建几何的保真度, 尤其是在显著物体边界附近。

在所提出的框架中, 每个高斯基元都扩展了一个额外的语义属性, 该属性由可学习的特征向量 $f_s \in \mathbb{R}^d$ 表示, 其中 d 表示语义嵌入空间的维度。与几何和光度属性不同, f_s 在外部监督下进行优化, 以编码高级上下文信息, 从而在重建过程中实现面向对象的正则化。

为了获得参考语义嵌入, 我们首先使用 BLIP3-o (Chen, Xu, Pan, Hu, Qin 等人, 2025) 为每个场景生成文本描述。然后, 这些描述被用来指导 Grounded-SAM (Ren, Liu, Zeng, Lin, Li, Cao, Chen, Huang, Chen, Yan 等人, 2024) 识别输入图像 I_{img} 中的感兴趣区域。该过程可以表示为:

$$\begin{aligned} R &= \{\mathcal{R}_k\}_{k=1}^K \\ &= \text{Grounded-SAM}(I_{\text{img}}, \text{BLIP3-o}(I_{\text{img}})), \\ I_{\mathcal{R}_k} &= I_{\text{img}}[\mathcal{R}_k], \\ f_{\text{ref},k} &= \text{CLIP}(I_{\mathcal{R}_k}), \quad k = 1, \dots, K. \end{aligned} \quad (6)$$

其中 $R = \{\mathcal{R}_k\}_{k=1}^K$ 表示检测到的语义区域集合, $\mathcal{R}_k$ 表示第 k 个语义区域, $I_{\mathcal{R}_k}$ 表示对应于第 k 个区域的裁剪图像块, $f_{\text{ref},k}$ 表示从该区域提取的 CLIP 嵌入。在实际操作中, 区域的数量是固定的 ($K = 3$ 个

我们的方法) 为每张图像选择, 以覆盖场景中的主要语义内容。每个选定的区域为监督落在该区域内的高斯原语提供区域级语义目标。

在训练过程中, 那些投影落在检测到的语义区域内的高斯原语被鼓励通过以下损失将它们的语义特征与相应的参考嵌入对齐:

$$L_s = \sum_{i \in \mathcal{G}_{\text{vis}}} \|f_s^{(i)} - f_{\text{ref}, r(i)}\|_2^2, \quad (7)$$

其中 $\mathcal{G}_{\text{vis}}$ 表示分配给语义区域的可见高斯基元集合, $r(i)$ 表示与第 i 个高斯投影相关联的语义区域索引。因此, $f_{\text{ref}, r(i)}$ 是根据其对应区域分配给第 i 个高斯的参考语义嵌入, $f_s^{(i)}$ 表示第 i 个高斯基元 G_i 的可学习语义特征。在区域重叠的情况下, 应用确定性的首次匹配规则, 而未被任何区域覆盖的高斯将从语义监督中排除。该损失以视图依赖的方式应用, 使可见性和遮挡通过标准 3DGS 渲染管线隐式处理。

语义术语被设计为辅助正则化, 而不是主要的监督信号。为此, 在优化过程中, 区域分配和目标嵌入被视为固定的, 语义特征不会直接参与渲染过程。这一设计减轻了噪声或不完美语义线索的影响, 这在水下图像中很常见, 并确保几何优化主要由光度一致性驱动, 同时受益于额外的语义指导。

这种额外的监督通过鼓励同一区域内的高斯基元表现出相似的语义特征, 促进语义-几何一致性, 从而在噪声、低能见度或稀疏视图条件下支持对象级的一致性, 并在光度线索受损的区域提高重建一致性。因此, 重建的场景表现出更好的结构一致性和感知质量。




图4: 对比未使用（上）和使用（下）自适应高斯基元重新分配过程的重建结果。重新分配产生了更加均衡的基元空间分布，如对应的归一化密度图所示，并通过优化后的更高PSNR值体现了更好的重建质量。在归一化密度图中，较暗的区域表示高斯密度较低。

4.2. 自适应高斯基元重新分配

现有基于 3DGS 的方法采用梯度驱动的密集化策略，其中利用位置梯度在优化过程中引入额外的高斯基元。虽然这种方法在提升局部细节方面有效，但可能导致表示的冗余 (Fang 和 Wang, 2024)，并可能限制整体重建质量。为了解决这一限制，我们提出了一种自适应高斯基元重新分配策略，该策略将基元从低贡献区域重新分配到重建误差较高的区域，从而提高表示效率和空间覆盖率。

类似于 Speedy-Splat (Hanson, Tu, Lin, Singla, Zwicker 和 Goldstein, 2025)，我们为每个高斯基元 i 定义一个重要性分数 $\tilde{S}_i$ ，基于它对渲染图像的贡献。具体来说，

$$\tilde{S}_i = \log \left| \nabla_{I_G} g_i \nabla_{I_G} g_i^T \right|, \quad (8)$$

其中 I_G 表示由所有高斯形成的渲染图像， $\nabla_{I_G} g_i$ 表示第 i 个高斯对 I_G 的贡献的梯度。

由于 g_i 是标量值且对数函数是单调递增的，重要性得分可以简化为

$$\tilde{S}_i = \left(\nabla_{I_G} g_i \right)^2, \quad (9)$$

它提供了对每个高斯基元渲染图像敏感性的度量。 $\tilde{S}_i$ 的较高值表示相应的基元对渲染图像具有更强的影响。

为了进一步提高重建质量，我们定义了一个误差分数 $\tilde{E}_i$ ，用于量化每个高斯基元对重建损失 L_{Rec} 的贡献：

$$\tilde{E}_i = \left(\nabla_{L_{\text{Rec}}} g_i \right)^2, \quad (10)$$

其中 $\nabla_{L_{\text{Rec}}} g_i$ 表示第 i 个高斯贡献相对于重建损失的梯度。

在致密化阶段之后，重要性得分 $\tilde{S}_i$ 和误差得分 $\tilde{E}_i$ 会定期评估（在本工作中每 3,000 次迭代进行一次）。基于 $\tilde{S}_i$ ，一部分得分最低的原始体（底部 10%）会被移除，因为这些对渲染输出的贡献最小。随后，对应的预算会通过克隆操作重新分配给具有最高误差得分（按 $\tilde{E}_i$ 排名前 10%）的原始体。具体来说，新原始体会与选定的高误差高斯体相同的属性进行初始化，然后通过优化进一步精炼，以更好地捕捉局部结构。剪枝和克隆的比例是经验性定义的；实际上，在合理范围内可以观察到稳定的性能，并且在消融研究中显示出持续的改进（表 2）。

图4说明了自适应高斯重新分配过程（下分支）与标准加密过程（上分支）的效果。每经过3,000次迭代，在加密停止后，重新分配开始，并伴随着一次移除10%低重要性原始元素的修剪步骤。由于表示能力的暂时下降，这一修剪阶段会导致重建质量略有下降（在示例中约为0.02 dB）。随后，重新分配过程会将释放的原始元素重新分配到重建误差较高的区域，从而实现更均衡的空间分布。这一效果在相应的归一化密度图中得到体现，归一化密度图由投影不透明度 α_i 得出，重新分配后显示出更为均匀的覆盖。经过进一步优化后，与没有重新分配的情况相比，重建质量显著提高，如图4右侧的两个结果所示，其中之前

总体而言，我们的自适应重新分配策略充当一种动态密度管理机制，通过将容量从低贡献区域转移到重建误差高的区域，从而提高表示效率。

这缓解了梯度驱动致密化引入的不平衡，减少冗余，并减轻过拟合，同时在整个优化过程中保持固定数量的高斯基元，从而保持实时渲染的计算效率。

4.3. 分阶段优化策略

为了提高优化的稳定性和重建质量，我们采用了两阶段的粗到精训练策略（图2，右下方面板）。

- 阶段 1（重建阶段）：重点是联合优化全局几何和外观。阶段 1 的损失主要由基于 ℓ_1 的重建项和 SSIM 组成，这对噪声具有鲁棒性。还加入了额外的损失项以保持结构一致性并建模水下成像物理，包括深度对齐、介质相关正则化、边缘平滑、语义对齐，以及一个小的 ℓ_2 项。该阶段促进在退化观测下对全局场景结构的稳健恢复。
- 阶段 2（精化阶段）：冻结几何和语义高斯参数，包括位置 f_{xyz} 、旋转 $f_{rotation}$ 、缩放 f_{scale} 和语义特征 f_s ，专注于外观精化。具体来说，与外观相关的参数将继续优化，而语义、深度和平滑正则项将被禁用，SSIM 项被移除，并在此阶段强调 ℓ_2 重建项，以增强细节和颜色一致性。

这种分阶段优化方案在噪声大和稀疏视角条件下提高了收敛性，降低了对介质引起的退化的敏感性，并在复杂的水下场景中实现了更一致的重建质量。在实验中，我们将重建阶段定义为前60%的迭代，将精炼阶段定义为总迭代的最后40%。这一划分作为一种实际的经验法则，最优的过渡点可能因数据集和场景特性而异。

4.4. 损失函数

训练过程遵循上述所述的两阶段优化计划，并由复合目标函数指导。基线损失，包括重建损失 L_{Rec} 、深度监督 L_{Depth} 、灰度世界先验 L_g 和边缘感知平滑 L_{Smooth} ，采用了我们之前的工作（Jiang 等，2025）。为了提高稳定性和外观建模，本文引入了额外的损失项。这些包括语义损失 L_s (Eq. 7)、用于精细化外观的逐像素均方误差项 L_2 ，以及约束预测衰减系数的铰链损失 $L_h \beta^d$ 和 β^b 。

总体目标函数被表述为

$$L_{\text{final}} = L_{\text{Rec}} + L_{\text{Depth}} + L_g + L_{\text{Smooth}} + \lambda_s L_s + \lambda_2 L_2 + \lambda_h L_h, \quad (11)$$

其中 λ_s 、 λ_2 和 λ_h 是权重参数，分别控制语义、均方误差和铰链项的贡献。对于插值帧，我们采用不确定性加权的公式：

$$L'_{\text{final}} = \frac{1}{2} \gamma L_{\text{final}} - \frac{1}{2} \zeta \log(\gamma), \quad (12)$$

其中 γ 表示学习到的不确定性， ζ 是正则化系数，如我们之前的工作中所详述（Jiang 等，2025）。

4.4.1. Base losses

L_{Rec} 重建损失结合了一个对异常值具有鲁棒性的平均绝对误差项和一个结构相似性 (SSIM) 项：

$$L_{\text{Rec}} = \lambda_1 (1 - \lambda_r) \|I_{\text{out}} - I_{\text{gt}}\|_1 + \lambda_r (1 - \text{SSIM}(I_{\text{out}}, I_{\text{gt}})), \quad (13)$$

其中 λ_1 是一个动态权重，定义为 $\lambda_1 = 0.7 + 0.5 \cdot (\text{迭代} / \text{总迭代})$ ，而 λ_r 控制 SSIM 项的贡献。具体来说， λ_r 在阶段 1 中设为 0.2，在阶段 2 中设为 0。

L_{Depth} 深度：深度 z 起着重要作用，因为 z 用于估计水下介质参数。因此，我们引入了一个深度监督项：

$$L_{\text{Depth}} = \lambda_d \|\hat{D} - D\|_1 + \lambda_{ca} \sum_{ch \in \{r, g, b\}} \sum_{n \in \{d, b\}} \|z_{ch}^n - D\|_1, \quad (14)$$

λ_d 和 λ_{ca} 是加权参数，在阶段1中分别设置为0.1和1，在阶段2中均设置为0。这里， D 表示参考深度， $\hat{D}$ 表示渲染深度。由于没有真实深度，使用 Depth Anything V 2 (Yang, Kang, Huang, Zhao, Xu, Feng 和 Zhao, 2024) 估计的伪深度进行监督。值得注意的是，水下场景被包含在其基准测试的一个场景中。术语 z_{ch}^n 表示每个颜色通道 ch 在直接光 ($n = d$) 和散射光 ($n = b$) 分量下推断的深度。

L_g ：灰度世界先验被应用于水下退化前的估计场景辐射，强制RGB通道的平均强度大致相等。目标值 0.5 对应灰度世界假设下的理想化平衡强度。它用于防止模型在恢复过程中收敛到不合理的色彩偏移。损失定义为

$$L_g = \sum_{ch \in \{r, g, b\}} (\mu(J_{ch}) - 0.5)^2, \quad (15)$$

其中 J_{ch} 表示通道 ch 的恢复像素值，归一化到范围 $[0, 1]$ ， $\mu(\cdot)$ 表示每个通道的平均强度。

$L_{\text{平滑}}$ ：惩罚与图像边缘不对齐的深度不连续，即允许在颜色处出现明显的深度边缘

边缘，但会在平滑区域对漂浮或噪声深度进行惩罚。我们的边缘感知平滑损失定义为，

$$L_{\text{Smooth}} = \lambda_m \sum_{i,j} \left[\exp(-\lambda_b |\Delta_x D_{i,j}|) |\Delta_x I_{i,j}| + \exp(-\lambda_b |\Delta_y D_{i,j}|) |\Delta_y I_{i,j}| \right], \quad (16)$$

其中 (i, j) 表示图像平面上的空间坐标， I 表示输入图像， D 表示伪深度图， $\Delta_x D_{i,j} = D_{i,j+1} - D_{i,j}$ 和 $\Delta_y D_{i,j} = D_{i+1,j} - D_{i,j}$ 分别表示深度图沿水平方向和垂直方向的前向差分。同样， $\Delta_x I_{i,j} = I_{i,j+1} - I_{i,j}$ 和 $\Delta_y I_{i,j} = I_{i+1,j} - I_{i,j}$ 是对应的图像梯度。这里， λ_b 固定为 5， λ_m 在阶段 1 设置为 0.05，在阶段 2 设置为 0。

4.4.2. Additional losses

本节描述了本文中引入的三个新的损失项。

L_s : 语义损失在公式 7 中定义。其权重系数 λ_s 在第 1 阶段的训练中按如下方式安排

$$\lambda_s = \max \left(0.01, 0.3 \cdot \left(1 - \frac{\text{iteration}}{\text{iterations}} \right) \right).$$

这在优化的早期阶段赋予较高的权重，此时全局结构正在建立，并在训练过程中逐渐降低其影响。在阶段 2 中，为了在没有额外语义约束的情况下进行细粒度外观精细调整，语义损失被禁用 ($\lambda_s = 0$)。

L_2 引入均方误差项以增强对高频细节和高对比度区域的敏感性。在阶段 1 中，它被分配较低的权重，并根据 0.1 次迭代逐渐增加。在阶段 2 中，其贡献增加到 0.9，以支持细粒度的外观优化。这种从 ℓ_1 主导到 ℓ_2 主导的优化过渡反映了在几何结构稳定后从全局结构学习到精确颜色和细节重建的转变。

L_h : 铰链项充当一种弱正则化 ($\lambda_h = 0.001$)，它鼓励在颜色通道之间保持一致的衰减排序，反映典型的水下成像行为，同时避免严格的物理约束。由于系数是按场景估计的，因此只强制执行它们的相对排序，从而允许在不同环境条件下具有灵活性。

对于所需的不等式 $a > b$ ，我们定义一个铰链损失为

$$L_{\text{hinge}}(a, b) = \max(0, b - a + m), \quad (17)$$

其中 $m \geq 0$ 是一个小的边距 (设置为 10^{-3})。当约束被满足时，损失为零，违反时线性增加。

根据水下光传播的波长依赖衰减行为，其中较长的波长衰减比短波长更快，我们施加




图5: SeaThru-NeRF 数据集 (Levy 等, 2023) 中每个场景的样本图像。




图6: Submerged3D 数据集 (江等, 2025) 中每个场景的示例图像。




图 7: S-UW 数据集 (Wang 等, 2025) 中每个场景的示例图像。

对衰减系数的一个排序约束，使得 $\beta_r^* > \beta_g^* > \beta_b^*$ 对于 $* \in \{d, b\}$ 。这实现为

$$L_h^* = \max(0, \beta_g^* - \beta_r^* + m) + \max(0, \beta_b^* - \beta_g^* + m), \quad (18)$$

表 1 SWAGSplatting 与六个基线模型（Instant-NGP（Müller, Evans, Schied 和 Keller, 2022）、SeaThru-NeRF（Levy 等, 2023）、3DGS（Kerbl 等, 2023）、WaterSplatting（Li 等, 2025）、UW-GS（Wang 等, 2025）和 RUSplatting（Jiang 等, 2025））在三个数据集（SeaThru-NeRF、S-UW 和 Submerged3D）上的性能比较。↑表示数值越高越好，而↓表示数值越低越好。红色、橙色和黄色分别表示最佳、次佳和第三佳结果。

SeaThru-NeRF															
Scene	Curacao			Panama			IUI-Redsea			Japanese-Redsea			Average		
Method	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
Instant-NGP	27.9215	0.7013	0.3961	23.4341	0.6294	0.4361	20.6162	0.5594	0.6121	23.2061	0.6371	0.3294	23.7945	0.6318	0.4434
SeaThru-NeRF	29.9162	0.8463	0.2984	26.9634	0.7261	0.3684	25.4989	0.7934	0.3684	21.8631	0.7569	0.3243	26.0604	0.7807	0.3399
3DGS	29.0234	0.9127	0.1790	30.7038	0.7606	0.1560	25.2240	0.9005	0.1970	22.3902	0.8638	0.1960	26.8353	0.8594	0.1820
WaterSplatting	31.4616	0.9256	0.1560	31.5367	0.9213	0.1445	22.1392	0.6598	0.2984	24.4323	0.8834	0.1494	27.3925	0.8475	0.1871
UW-GS	29.9721	0.9220	0.1770	31.0023	0.9335	0.1432	28.5473	0.9243	0.1885	23.5013	0.8625	0.1916	28.2558	0.9106	0.1751
RUSplatting	30.9557	0.9318	0.1611	31.8683	0.9339	0.1396	29.8036	0.9292	0.1847	24.5436	0.8706	0.1809	29.2928	0.9164	0.1666
Ours	33.0521	0.9481	0.1428	32.0630	0.9389	0.1264	30.3602	0.9306	0.1822	24.3617	0.8861	0.1772	29.9593	0.9260	0.1571
Submerged3D															
Scene	Cormoran			Isro			Kwaj			Tokai			Average		
Method	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
Instant-NGP	19.5271	0.5055	0.5505	20.1861	0.6588	0.4146	18.1444	0.4682	0.4535	18.2488	0.4082	0.5723	19.0266	0.5102	0.4977
SeaThru-NeRF	16.8816	0.4533	0.6118	21.5887	0.6501	0.5025	20.7094	0.5116	0.5240	17.6072	0.3720	0.6360	19.1967	0.4968	0.5686
3DGS	20.4698	0.6756	0.3852	22.8198	0.8421	0.3008	24.0964	0.8485	0.2276	23.2345	0.6517	0.4017	22.6551	0.7545	0.3288
WaterSplatting	21.0749	0.6482	0.3846	26.2920	0.8517	0.2716	27.8613	0.8709	0.2162	23.1047	0.6362	0.3965	24.5832	0.7518	0.3172
UW-GS	20.6942	0.6800	0.3412	24.6752	0.8649	0.2683	28.4065	0.8868	0.2105	23.5880	0.6578	0.3833	24.3410	0.7724	0.3008
RUSplatting	21.9625	0.6846	0.3662	27.8693	0.8680	0.2670	28.9058	0.8774	0.2253	24.4585	0.6599	0.3548	25.7990	0.7725	0.3033
Ours	21.9794	0.7023	0.3482	28.1544	0.8782	0.2643	28.8320	0.8847	0.2161	25.6028	0.7391	0.3612	26.1422	0.8011	0.2974
S-UW															
Scene	Lagoon			Marine			Reef			Seabed			Average		
Method	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
Instant-NGP	21.6674	0.5480	0.3198	15.7300	0.4637	0.4410	18.5866	0.4382	0.5058	19.6167	0.4275	0.3198	18.9002	0.4694	0.3966
SeaThru-NeRF	25.5424	0.7592	0.2860	18.1031	0.5718	0.4582	18.5510	0.4077	0.5522	22.7050	0.6407	0.3455	21.2254	0.5949	0.4105
3DGS	27.1166	0.8707	0.1606	18.9492	0.6922	0.2990	22.4663	0.7117	0.2646	26.4933	0.8234	0.1684	23.7564	0.7745	0.2232
WaterSplatting	27.1979	0.8685	0.1135	19.6173	0.6869	0.2619	26.6378	0.7971	0.1769	26.0623	0.8136	0.1516	24.8788	0.7915	0.1760
UW-GS	26.9103	0.8736	0.1479	20.0065	0.7145	0.2678	23.3078	0.7277	0.2504	26.5088	0.8197	0.1541	24.1834	0.7839	0.2051
RUSplatting	27.6000	0.8659	0.1719	20.9329	0.7447	0.2706	26.7588	0.8154	0.2222	27.0903	0.8292	0.1771	25.5955	0.8138	0.2105
Ours	27.5294	0.8659	0.1625	20.7229	0.7328	0.2764	26.8547	0.8127	0.2124	27.4631	0.8370	0.1553	25.6425	0.8121	0.2017

下标表示 RGB 通道。虽然这种排序反映了清水中典型的衰减行为，但在某些环境中（例如富含叶绿素的沿海水域）可能会出现偏差，而且这种偏差可以很容易地调整。因此，铰接项充当的是一种弱正则化，而不是严格的约束。

最终的铰链损失定义为

$$L_h = \frac{1}{2}(L_h^d + L_h^b). \quad (19)$$

在实践中，我们发现将 L_h 整合到优化中可以将渲染质量提高约 0.066 dB。然而，它也提高了训练的稳定性，这可以从总体训练损失特别是 L_{Rec} 中观察到。

5. 数据集

我们在三个公开的真实水下数据集上评估所提出的方法，分别是 SeaThru-NeRF (Levy 等, 2023)、Submerged3D (Jiang 等, 2025) 和 S-UW (Wang 等, 2025)。这些数据集展示了水下图像的不同特性，为评估 3D 重建方法的鲁棒性和泛化能力提供了互补的测试条件。所有图像均被调整为 720p 分辨率，以确保实验的一致性。

SeaThru-NeRF 包含在三个海洋环境中拍摄的四个场景，包括红海（IUI3-RedSea 和 Japanese-RedSea）、加勒比海（库拉索）和太平洋（巴拿马）。这些场景分别包含 20、20 和 18 张 RGB 图像，每个场景有三张图像用于验证。该数据集涵盖了多种水下成像条件和场景复杂性。如图 5 所示，所有场景都描绘了珊瑚礁环境，可见度和光照变化相对有限。

Submerged3D 包含四个场景：关岛附近的 SMS Cormoran 和 Tokai Maru 号沉船，Mellu 岛附近的 Kwajalein 环礁 F4U-1 Corsair 残骸，以及靠近加那利群岛的 S S America (Isro)。每个场景都来源于更大的数据集，从中选择 20 张 720p 分辨率的 RGB 图像进行处理。数据由国家公园管理局沉没资源中心提供¹。由于视角稀疏、光线不足以及图像严重退化，该数据集在 3D 重建方面具有显著挑战。示例场景如图 6 所示。为了评估，我们遵循预定义的划分，将每第八张图像分配到测试集，其余图像用于训练。

¹Cleaned photogrammetry models (with water removed) are available at <https://www.npssubmerged.com/photogrammetry>




图8: 新视角渲染对比。第一行显示了来自SeaThru-NeRF数据集的IUI-Redsea场景的结果, 第二行显示了来自Submerged3D数据集的Isro重建场景。第三行左侧显示了Japanese-Redsea的重建场景, 右侧显示了Submerged3D数据集的Tokai。第四行是来自S-UW数据集的结果, 分别显示了Reef (左) 和Seabed (右) 的重建场景。

S-UW 包含四个场景, 这些场景在泰国克拉比附近的岛屿拍摄, 每个场景由 24 张 RGB 图像组成。该数据集是在浅水环境中获取的, 呈现出额外的挑战, 包括由动态水面运动引起的明显闪烁 (如图 7 所示)。这些场景主要以纹理丰富的珊瑚礁结构为主, 而有些序列还包含游动的鱼类, 由于非刚性运动, 这增加了进一步的复杂性。

6. 实验与结果

6.1. 实验设置

所有实验均在单个 NVIDIA RTX 4090 GPU 上进行。我们使用 COLMAP (Schonberger 和 Frahm, 2016) 来初始化点云并估计图像序列的相机位姿。我们修改了原始 3DGS 中使用的 diff-gaussian 光栅化模块以进行渲染

深度图, 在深度损失的反向传播中引入了一个额外的梯度计算分支 L_{Depth} 。超参数 λ_h 固定为 1×10^{-3} , 而 λ_s 和 λ_2 在训练过程中动态调整。具体而言, λ_s 从 0.3 衰减到 0.01, 然后在微调阶段设置为 0, 而 λ_2 从 0 线性增加到 0.1, 然后在微调阶段设置为 0.9。为了估计 3DGS 参数, 我们使用了一个五层的 MLP, 该模型是基于超参数敏感性分析选择的。

每个模型训练 20,000 次迭代, 第二阶段优化从第 12,000 次迭代开始。为了提高计算效率, 参考语义嵌入 $\{f_{\text{ref},k}\}_{k=1}^K$ 在训练开始时预计算并缓存以供重复使用。投影后的 CLIP 嵌入空间的维度设置为 $d = 32$ 。对于帧插值, 我们采用实时中间流估计 (RIFE) (Huang, Zhang, Heng, Shi 和 Zhou, 2022), 遵循 RUSplatting。使用固定权重因子 0.1 替代自适应权重, 以提供稳定性




图9: 工作流程展示了使用COLMAP从输入图像创建的点云, 在某些区域存在噪声并且稀疏。经过训练后, 用于新视角渲染的点云变得更干净。显示了每个三维点的椭球体, 说明它们如何用于创建最终渲染结果。

在不同数据集上, 重建精度与插值质量之间存在权衡。在实践中, 我们观察到在一系列数值下收敛稳定, 并且当任一项被移除时性能下降, 这表明两个模块都有贡献。

我们将所提出的方法与六个具有代表性的基线进行比较: Instant-NGP (Müller 等, 2022)、SeaThru-NeRF (Levy 等, 2023)、3DGS (Kerbl 等, 2023)、Water-Splatting (Li 等, 2025)、UW-GS (Wang 等, 2025) 和 RUSplatting (Jiang 等, 2025)。一些近期的方法, 包括 Aquatic-GS (Liu 等, 2024)、RecGS (Zhang 等, 2025)、R-Splatting (Huang 等, 2025b) 和 AtlantisGS (Yi 等, 2025), 未公开, 因此未被纳入比较。尽管 SeaSplat (Yang 等, 2025) 提供了官方代码, 但我们在推荐设置下训练时观察到数值不稳定, 因此将其排除在比较之外。

为了公平评估, 所有基线方法均使用其官方代码库实现, 并在相同的图像序列和优化设置下进行训练, 遵循相同的数据集划分协议。损失权重采用先前工作的设置, 以确保公平比较。

6.2. 定量比较

定量性能使用三种标准指标评估: 峰值信噪比 (PSNR)、结构相似性指数 (SSIM) 以及学习感知图像块相似性 (LPIPS) (Zhang, Isola, Efros, Shechtman 和 Wang, 2018), 它们分别衡量像素级准确性、结构相似性和感知质量。

表1展示了所提方法与六种基线方法在三个数据集上的定量比较。跨所有数据集平均, 所提方法在所有三项指标上都达到了最佳性能, 显示了在重建精度和感知质量方面的一致提升。

在 SeaThru-NeRF 数据集上, 我们的方法超过了最强的基线方法 RUSplatting, 在 PSNR 上平均提高了 0.67 dB, SSIM 提高了 1.05%, LPIPS 降低了 5.70%。值得注意的是, 所有场景都观察到了改进, 这表明在不同水体条件下具有稳健的性能。

在更具挑战性的 Submerged3D 数据集上, 该数据集具有稀疏的视角和严重的图像退化, 所提出的方法仍然优于现有的方法。与 UW-GS 相比, 它在 PSNR 上平均提升了 1.80 dB, 在 SSIM 上提升了 3.72%, 同时 LPIPS 下降了 1.13%。这些提升证明了所提出方法在处理低能见度和稀疏视角场景中的有效性。

在四个场景的 S-UW 数据集上, 我们的方法在 PSNR (25.6425 dB) 方面取得了最佳平均性能, 同时在 SSIM (0.8121) 和 LPIPS (0.2017) 方面也具有竞争力。较高的 PSNR 结果可能源自我们优化策略的第二阶段, 其中强调了 ℓ_2 项。值得注意的是, 不同方法表现出不同的权衡。例如, WaterSplatting 达到最低的平均 LPIPS, 表明其感知相似性更强, 而 RUSplatting 在某些场景下获得了较高的 SSIM 和强 PSNR。相比之下, 我们的方法在所有指标和场景中提供了更均衡的性能, 在任何特定场景下都没有显著下降。这种一致性对于 S-UW 的浅水场景尤为重要, 因为闪烁和非刚性运动带来了额外的挑战。

总体而言, 这些结果证明了我们基于语义引导的分阶段优化和高斯重新分配策略在增强结构一致性和感知质量方面的有效性, 即使在从相对受控的珊瑚礁环境到高度退化的深海场景的各种挑战性水下条件下。

表 2 Ablation 结果, 在 SeaThru-NeRF、Submerged3D 和 S-UW 数据集的所有场景上取平均。红色、橙色和黄色分别表示第一、第二和第三的结果。

Variant	SG	SO	AR	PSNR↑	SSIM↑	LPIPS↓
M1	✗	✓	✓	27.4453	0.8373	0.2426
M2	✓	✗	✓	27.8131	0.8511	0.2355
M3	✓	✓	✗	27.8604	0.8632	0.2297
Ours	✓	✓	✓	28.0508	0.8636	0.2272

SG: 语义引导高斯; SO: 分阶段优化; AR: 自适应高斯原语重新分配

6.3. 定性比较

图 8 中的定性结果展示了所提出方法相较于现有方法的视觉性能。基线方法在重建精细几何结构和保持背景一致性方面表现出明显的局限性, 尤其是在受散射和低能见度影响的区域 (图中第一行黄色和红色高亮区域, 这些来自 seaThru-NeRF 数据集)。例如, 几种方法无法恢复珊瑚的细小尖刺结构, 或者产生不一致的背景纹理。相比之下, 所提出的方法能够保留这些复杂的细节, 从而获得更清晰、更真实的重建效果。

对于 Submerged3D 数据集, 图 8 的第二行显示, 所提出的方法在几何精度和颜色表现的一致性上都有提升, 而竞争方法则表现出明显的伪影 (例如 RUSplatting) 或模糊的结构 (例如 UW-GS)。第三行进一步确认了所提出方法在保持复杂场景中的细微结构细节和感知质量方面的优势。第四行显示了在 S-UW 数据集上的结果。虽然表 1 的定量结果显示 RUSplatting 达到了最佳 PSNR, 但定性结果表明, 当不同视角的光照变化时, 它在准确重建内容方面存在困难。尽管 WaterSplatting 获得了最佳感知质量指标 (LPIPS), 但其结果虽然看起来比我们提出的 SWAGSplatting 更清晰, 也在裁剪区域中引入了伪影。总体而言, 结果表明所提出的方法能产生更一致和更

图9展示了三维渲染工作流程。图中显示, COLMAP重建包含明显的噪声和不规则的点分布, 尤其是在受低能见度和散射影响的区域。这些伪影是由在复杂的水下条件下特征匹配不可靠和深度估计不准确引起的。相比之下, 经过优化后, 我们方法生成的点云更加连贯且空间上更一致。噪声显著减少, 结构性




图10: 语义引导示例。从左到右: 输入场景、生成描述和分割图。

细节得到更好的保留, 从而产生更清晰、更完整的场景表示。这些结果表明, 在退化的水下环境中, 所提出的方法比传统基于摄影测量的方法产生更高质量的几何表示。在这些环境中, 通常需要额外的后处理, 例如滤除异常值和噪声, 以及可选的下采样或数据清理, 才能获得可用的重建结果。

6.4. 消融研究

为了评估所提框架中各组件的贡献, 我们进行了消融实验, 其配置和结果总结在表2中。从完整模型开始, 移除任何单个组件都会导致所有指标的性能一致下降, 这表明每个模块都对整体重建质量有正向贡献。

在这些方法中, 移除语义指导 (M1) 导致性能下降最大。这突出显示了语义模块作为感知层正则器的作用, 它在不依赖显式类别标签的情况下改善了区域级一致性。通过利用CLIP嵌入, 语义上相似的区域被鼓励表现出一致的表示, 从而在光度线索模糊或退化的区域稳定重建。图10展示了生成的描述及其对应的语义分割图的示例。鉴于带注释的水下数据集的有限性, 评估是在已建立的基准上进行的, 因此结论仅限于在这些条件下的重建性能。

变体 M2 移除了分阶段优化组件, 同时保留了语义引导和高斯重新分配。在没有分阶段训练的情况下, 模型在整个训练过程中会联合优化几何结构和外观, 这可能导致不稳定和次优的细化, 尤其是在成像条件恶劣时。完整模型中的分阶段策略有助于将全局结构学习与细粒度外观优化解耦, 从而实现更稳定的收敛和更高的重建精度。

移除自适应高斯重新分配组件 (M3) 会导致相对较小的性能下降。这是预期中的, 因为重新分配机制主要通过将低贡献区域的基元重新分配到重建误差更高的区域来提高表示效率。其影响更具局部性 (如图4所示), 因此在固定基元预算下, 对场景级平均指标的影响较小。

总体而言, 完整模型达到了最佳性能, 这表明所提出的组件在结合时提供了互补的优势。

7. 结论

本文提出了一种基于语义引导的三维高斯点映射框架, 用于水下场景重建。所提出的方法通过为每个高斯基元扩展可学习的语义特征, 并利用基于CLIP的嵌入进行监督, 以促进语义与几何的一致性。引入语义损失以鼓励高层次结构关系的保持, 从而提升感知质量。此外, 还采用了分阶段优化策略以增强训练稳定性, 并提出了一种自适应高斯重新分配机制, 通过在固定预算内重新分配基元来提高表示效率。这些组件共同使在复杂水下环境下实现更一致和更详细的重建成为可能。实验证明, 所提出的方法在多个基准测试中取得了性能提升。代码将在论文被接受后发布。

CRedit 作者贡献声明

蒋卓东: 撰写 - 审阅与编辑, 撰写 - 原始稿件, 可视化, 验证, 方法学, 数据整理, 概念化。王浩然: 撰写 - 审阅与编辑, 撰写 - 原始稿件, 可视化, 验证, 方法学, 概念化。黄国熙: 撰写 - 审阅与编辑, 方法学。布雷特·西摩: 数据整理, 资源。南蒂拉·阿南特拉西查伊: 撰写 - 审阅与编辑, 方法学, 概念化, 监督, 资源, 项目管理, 资金获取。

利益冲突声明

作者声明他们没有已知的可能影响本文所报告工作的竞争性财务利益或个人关系。

致谢

这项工作得到了英国研究与创新局 (UKRI) “My World地区优势计划” (SIPF00006/1) 和工程与物理科学研究理事会 (EPSRC) ECR (EP/Y002490/1) 的支持。

参考文献

- Akkaynak, D., Treibitz, T., 2018. 修订版水下图像形成模型, 载于: IEEE/CVPR计算机视觉与模式识别会议论文集, 第6723–6732页。doi:10.1109/CVPR.2018.00703. Akkaynak, D., Treibitz, T., 2019. Sea-thru: 一种去除水下图像中水分的方法, 载于: IEEE计算机视觉与模式识别会议论文集, 第1682–1691页。Bekerman, Y., Avidan, S., Treibitz, T., 2020. 揭示水下图像中的光学特性, 载于: 2020 IEEE国际计算摄影会议 (ICCP), 第1–12页。doi:10.1109/ICCP48838.2020.9105267. Bryson, M., Johnson-Roberson, M., Pizarro, O., Williams, S.B., 2016. 自主水下航行器影像的真实色彩校正。野外机器人学报 33, 853–874。Burns, J.H.R., Delporte, D., 2017. 比较用于珊瑚礁环境水下三维建模的商业结构光学测量摄影测量软件。摄影测量与遥感国际档案

- Levy, D., Peleg, A., Pearl, N., Rosenbaum, D., Akkaynak, D., Korman, S., Treibitz, T., 2023. Seathru-nerf: 散射介质中的神经辐射场, 载于: 计算机视觉与模式识别会议 (CVPR) 论文集, 第56–65页。Li, H., Song, W., Xu, T., Elsig, A., Kulhanek, J., 2025. WaterSplatting: 使用高斯散点的快速水下三维场景重建, 载于: 国际三维视觉会议 (3DV)。Liu, S., Lu, J., Gu, Z., Li, J., Deng, Y., 2024. Aquatic-GS: 水下场景的混合三维表示。arXiv:2411.00239。Mildenhall, B., Srinivasan, P.P., Tancik, M., Barron, J.T., Ramamoorthi, R., Ng, R., 2021. NeRF: 将场景表示为用于视图合成的神经辐射场。ACM通讯 65, 99–106。Müller, T., Evans, A., Schied, C., Keller, A., 2022. 具有多分辨率哈希编码的即时神经图形原语。ACM图形学交易 41, 1–15。Radford, A., Kim, J.W., Hallacy, C., Ramesh, A., 等, 2021. 学习 (CVPR), 第586–595页。doi:10.1109/CVPR.2018.00068。Zhang, T., Zhang, W., Meyers, B., Durrant, N., 等, 2025. RecGS: 利用循环高斯散射去除水中的焦散。《IEEE机器人与自动化快报》 10, 668–675. doi:10.1109/LRA.2024.3511418。Zhong, J., Li, M., Gruen, A., Schindler, K., Liao, X., Guo, Q., 2025. 水下珊瑚礁图像的前沿三维重建解决方案: 综述与比较。《ISPRS摄影测量与遥感杂志》 230, 779–803. doi:https://doi.org/10.1016/j.isprsjprs.2025.10.009。Zhou, J., Liang, T., Zhang, D., Liu, S., Wang, J., Wu, E.Q., 2025. WaterHE-NeRF: 用于水下场景重建的水光线匹配神经辐射场。《信息融合》 115, 102770。