

语义引导的 Gaussian Splatting：用于高保真水下场景重建

Zhuodong Jiang, Haoran Wang, Guoxi Huang, Brett Seymour, Nantheera Anantrasirichai

arXiv:2509.00800v3, 2026-04-21

语义引导的 Gaussian Splatting：用于高保真水下场景重建

Zhuodong Jiang, Haoran Wang, Guoxi Huang, Brett Seymour, Nantheera Anantrasirichai

a. School of Computer Science, University of Bristol, Bristol, UK

b. Submerged Resources Centre, Denver, CO, USA

译文说明：本文档根据本地文件 2509.00800v3.pdf 翻译整理。为便于阅读，译文采用单栏 Markdown 结构；图像本体未嵌入，但图注已翻译；公式、方法名、数据集名、指标名、引用标识尽量保留原文形式。

文章信息

关键词：3D Reconstruction; Gaussian splatting; Semantic-aware 3D reconstruction; Underwater scene reconstruction

摘要

在退化成像条件下实现准确的 3D 重建，仍然是摄影测量和神经渲染中的关键挑战。在水下环境中，由散射、衰减和稀疏观测造成的空间可见性变化，会导致信息质量高度不均匀。现有 3D Gaussian Splatting (3DGS) 方法通常只基于光度信号优化 primitive，结果容易产生不平衡的表示：观测充分区域过拟合，而退化区域重建不足。

本文提出 SWAGSplatting (Semantic-guided Water-scene Augmented Gaussian Splatting)，这是一个将语义先验集成到 3DGS 中的多模态框架，用于鲁棒、高保真的水下重建。每个 Gaussian primitive 都被扩展为带有可学习语义特征，并由基于 CLIP 的区域级线索嵌入进行监督。本文引入语义一致性损失，使几何重建与高层语义对齐，从而在困难条件下改善结构一致性并保留显著目标边界。

此外，本文提出一种自适应 Gaussian primitive 重分配策略，根据 primitive 重要性和重建误差重新分配表示容量，以缓解传统 densification 引入的不均衡问题。该策略能够在不增加计算成本的情况下，更有效地建模低可见性区域。基于 SeaThru-NeRF、Submerged3D 和 S-UW 等真实世界数据集的大量实验表明，所提方法在平均 PSNR、SSIM 和 LPIPS 指标上持续优于当前先进方法。结果验证了语义先验对高保真水下场景重建的有效性。代码地址：<https://github.com/theflash987/SWAGSplatting>。

1. 引言

水下探索支撑了机器人、考古学和海洋生态学等广泛应用，这些应用都依赖准确的 3D 重建来进行可视化、解释和导航。主动传感方式（如 sonar 和 LiDAR）能够提供直接距离测量，但它们在水下使用时受限于分辨率、成本和操作复杂度。声学传感器可以实现远距离感知，但通常只能生成低分辨率重建；水下 LiDAR 则会受到强衰减和后向散射影响，从而限制有效距离。相比之下，基于图像的方法依赖被动传感和易获得的相机系统，成本更低，空间分辨率更高，更适合细节重建。

不过，水下环境具有独特挑战，例如有限可见性、颜色失真、稀疏视角、marine snow，以及由光衰减和散射引起的噪声。在深水环境中捕获视频尤其困难，因为低光照条件需要更长曝光时间或更高 ISO，而这两者都会引入明显运动模糊和传感器噪声。静态图像采集也经常受限且分布不均，这进一步增加了可靠 3D 重建的难度。

长期以来，基于摄影测量的方法一直是 3D 场景重建的基础，在水下环境中同样如此。这类方法通常通过 Structure-from-Motion (SfM) 和 Multi-View Stereo (MVS) 流程，从多视图图像对应关系和相机标定恢复几何结构，在良好成像条件下估计相机位姿和密集表面几何。然而，在低纹理、散射和非均匀照明等困难场景中，可靠特征匹配和深度估计会变得困难，性能因此下降。此外，这类流程计算成本较高，限制了其在大规模或时间敏感任务中的应用。

近年来，神经渲染通过 novel view synthesis (NVS) 为 3D 重建提供了替代范式。Neural Radiance Fields (NeRF) 通过建模连续体积表示实现高质量重建，但需要密集输入视图并带来显著计算开销。3D Gaussian Splatting (3DGS) 则作为一种高效的显式表示出现，能够更快优化并实时渲染。尽管如此，大多数 NeRF 和 3DGS 方法都假设成像条件清晰，在浑浊水下环境中的性能会明显下降。已有方法将水下图像退化模型引入重建流程，并取得有希望的改进，但仍存在一个关键限制：这些方法在优化时通常将所有场景区域均匀对待。

在水下场景中，视觉信息在空间上高度不均匀。前景目标通常比受到散射和衰减影响的背景区域提供更强、更可靠的信号。如果缺少显式引导，标准优化过程会优先关注观测充分区域，从而稀释语义重要区域或退化区域的贡献。这会导致显著结构模糊或几何不一致。一个相关限制来自梯度驱动的 Gaussian densification：它根据光度信号强度分配 primitive。在退化成像条件下，这会产生不平衡的 primitive 分布：观测充分区域累积冗余 Gaussians，而困难区域表示不足，最终限制重建保真度。

为了解决这些问题，本文提出用于水下 3D 重建的语义增强 Gaussian splatting 框架 SWAGSplatting。该方法将语义先验与物理建模结合，以改善困难成像条件下的重建。具体而言，来自 vision-language model (如 CLIP) 的语义线索提供高层上下文信息，补充光度监督。CLIP 从大规模图文数据中学习可迁移的视觉-语义对应关系，因此无需任务特定训练即可跨域泛化。本文通过语义一致性损失引入该信息，作为辅助正则项，将每个 Gaussian 的语义特征与区域级语义嵌入对齐。重要的是，该正则作用在特征空间，并不直接修改位置或 opacity 等几何参数。因此，所提公式在保留底层几何表示的同时，提高结构一致性和目标级一致性。

此外，标准 3DGS 依赖梯度驱动的 densification，根据光度信号强度分配 primitive。在退化成像条件下，这会使观测充分区域主导优化，而低可见性区域表示不足，导致表示容量低效使用。本文提出自适应 Gaussian 分配策略，根据重建难度重新分配表示容量，使空间覆盖更均衡，并提高重建保真度，如图 1 所示。

本文主要贡献如下：

- 提出一种语义引导的 3D Gaussian Splatting 框架用于水下场景重建。每个 Gaussian primitive 都被扩展为带有可学习语义特征，该特征来自 vision-language embedding，从而实现目标感知和语义一致的重建。
- 引入语义引导损失，使语义表示与几何表示对齐，在退化成像条件下提高结构一致性并保留显著目标边界。
- 提出自适应 Gaussian primitive 重分配策略，将低重要性 primitive 重新分配到高误差区域，以平衡 Gaussian 点云分布并提高 NVS 质量。
- 引入 stage-wise optimization，即从粗到细的训练方案，通过后期参数冻结和 L2 fine-tuning 提高稳定性与视觉质量。

本文在 SeaThru-NeRF、Submerged3D 和 S-UW 数据集上进行综合评估，结果显示相对于先进 baseline，PSNR 最高提升 3.48 dB，并在 SSIM 和 LPIPS 上取得持续改进。

图 1：3DGS、UW-GS 与本文 SWAGSplatting 的重建性能对比。相较于 3DGS 和 UW-GS，SWAGSplatting 明显抑制 artifact 生成，并得到更忠实的渲染结果。

2. 相关工作

在神经渲染兴起之前，水下 3D 重建主要依赖基于 SfM 和 MVS 的摄影测量流程。COLMAP 等系统从跨图像特征对应关系中提取稀疏点云，再通过立体匹配进行 densification，构成许多水下测绘流程和商业软件的基础。然而，这些方法通常假设 Lambertian 表面和一致照明，而水下环境很少满足这些条件。散射、后向散射和波长相关衰减会破坏特征检测与立体匹配。

为了改善输入质量，常见预处理包括直方图均衡、dark channel prior 去雾或 Sea-thru 颜色校正，但这些方法无法完全补偿严重退化，尤其是在深水或浑浊水域中。声学传感提供了互补路径，例如 multibeam sonar 和结构光系统可以在不依赖光学条件的情况下恢复几何，但通常生成稀疏或缺少纹理的重建。

近期经典方法还探索了用于实时水下重建的 stereo vision 和 SLAM。基于 stereo 的系统利用 epipolar geometry 恢复密集深度图，并通过水下特定标定模型处理相机壳体界面的折射失真。适配水下环境的视觉 SLAM 系统可以融合惯性测量或 sonar 约束，在机器人运动过程中增量构图。这些方法适合在线导航任务，但通常比离线神经网络渲染流程生成的重建保真度更低，并且难以处理动态照明和介质散射引入的外观不一致。摄影测量和 SLAM 方法在处理水下光学退化方面的局限，推动研究转向学习方法，先是 NeRF，随后是 3DGS。

2.1 基于 NeRF 的水下场景重建

将 NeRF 扩展到散射介质中近年来受到越来越多关注，其目标是将场景几何与介质导致的退化解耦。早期工作如 ScatterNeRF 显式地将体积衰减与目标几何分开建模，为参与介质中的渲染提供了有物理依据的公式。

SeaThru-NeRF 基于修订后的水下图像形成模型，引入专门网络组件，分别建模 transmittance 和 medium color，从而更好地将场景外观与水体影响解耦。后续工作聚焦于在该框架下提升重建质量。例如 SP-SeaNeRF 引入可学习照明嵌入，以提升锐度和细节保留。另一类工作通过物理启发模型处理颜色退化。WaterNeRF 将光传输建模与 optimal transport 结合用于颜色校正；WaterHE-NeRF 采用基于 Retinex 的公式补偿波长相关衰减。这些方法强调了准确颜色建模对于感知一致重建的重要性。

处理动态元素仍是水下环境中的关键挑战。UWNeRF 通过分离静态区域和动态区域提高重建稳定性，但它依赖准确 mask。AquaNeRF 使用 single-surface-per-ray 公式和 Gaussian-weighted transmittance 缓解动态 artifact，减少对显式分割的依赖。

尽管已有进展，NeRF 方法仍受限于对密集输入视图的依赖、高计算成本和有限渲染效率。这些限制推动了对更高效显式表示的采用，例如下一节讨论的 3DGS。

2.2 基于 3DGS 的水下场景重建

3D Gaussian Splatting (3DGS) 的近期进展使得基于显式点表示的高效、高质量场景重建成为可能。与 NeRF 方法相比，3DGS 训练更快，并支持实时渲染，因此适合大规模和交互式应用。然而，由于散射、衰减和动态干扰，将 3DGS 直接应用于水下环境仍然具有挑战。

早期水下 3DGS 改造主要关注引入光传播物理模型。UW-GS 引入 physics-aware density control、pseudo-depth supervision 和 motion masking，以抑制散射和动态干扰物影响。WaterSplatting 显式建模 object transmittance 和 medium transmittance，以在不同水体条件下提升真实感。Aquatic-GS 将隐式水体表示与显式 Gaussian primitive 结合，以实现物理一致的重建。

后续研究探索了多种策略以增强神经渲染方法在水下环境中的鲁棒性。例如 SeaSplat 将水下图像形成模型纳入 3DGS 框架，将场景 radiance 与介质影响解耦，从而提升颜色保真度和几何重建。不过该方法主要面向静态场景，在更复杂或动态环境中可能不够有效。RecGS 采用循环优化策略，逐步细化重建以抑制水体 artifact，在退化视觉条件下提高稳定性。RUSplatting 引入 uncertainty-aware 建模机制，估计观测可靠性，并在优化中降低噪声或损坏输入的影响。R-Splatting 集成预训练图像增强网络，以缓解浅水场景中尤其明显的照明退化和颜色失真。

另一个方向关注结构分解和表示设计。AtlantisGS 将前景目标与背景介质分离，并向显著区域分配更多 primitive，以改善稀疏视图条件下的重建质量。这些方法表明，Gaussian 表示需要适应场景结构和环境影响。

现有方法大多聚焦低层图像恢复或观测加权，往往忽略了高层结构或语义线索的作用，而这些线索本可以在空间可见性变化较大时进一步稳定重建。这一限制促使本文开发将额外先验引入几何优化的水下重建方法。

3. 预备知识

3.1 3D Gaussian Splatting (3DGS)

3D Gaussian Splatting 将场景表示为一组显式 primitive，即各向异性 3D Gaussians。每个 Gaussian G_i 由均值位置 $\mu_i \in \mathbb{R}^3$ 、协方差矩阵 $\Sigma_i \in \mathbb{R}^{3 \times 3}$ 、opacity α_i （或密度贡献）以及视角相关颜色 c_i 参数化。协方差矩阵编码每个 primitive 的空间范围和方向，使各向异性 Gaussian 能够比各向同性表示更高效地近似局部表面几何。

渲染时，每个 Gaussian 通过相机投影模型从 3D 空间投影到 2D 图像平面。设 x 为图像空间中的像素位置。投影 Gaussian 对 x 的贡献建模为 2D Gaussian 分布：

$$G_i(x) = \exp\left(-\frac{1}{2}(x - \mu_i)^\top \Sigma_i^{-1}(x - \mu_i)\right)$$

其中 μ_i 和 Σ_i 表示屏幕空间中的投影均值和协方差。这一公式通过在图像空间评估每个 Gaussian 的影响，实现高效 rasterization。

为便于可微优化，3D Gaussian primitive 中的协方差矩阵 Σ_i 被分解为旋转矩阵 $R_i \in \mathbb{R}^{3 \times 3}$ 和缩放矩阵 $S_i \in \mathbb{R}^{3 \times 3}$ ：

$$\Sigma_i = R_i S_i S_i^T R_i^T$$

为了处理可见性和遮挡，Gaussians 使用 front-to-back alpha blending 组合。像素 x 处最终颜色为：

$$C(x) = \sum_{i=1}^N \alpha_i c_i(v) \prod_{j=1}^{i-1} (1 - \alpha_j)$$

其中 v 表示观察方向， $c_i(v)$ 通常用 spherical harmonics (SH) 表示以建模视角相关外观。乘积项表示沿 ray 累积的 transmittance，从而保证正确的可见性顺序。

Gaussian 的位置、协方差、颜色和 opacity 等参数，通过最小化渲染图像与观测图像之间的光度重建损失进行梯度优化。为提高场景覆盖，3DGS 使用 adaptive densification，在高重建梯度区域引入额外 Gaussians。虽然这在观测充分区域有效，但在非均匀成像条件下，梯度驱动分配会导致 primitive 分布不均衡，这正是本文要解决的问题。

3.2 水下图像形成

水下图像形成由光与周围介质的相互作用决定，因此比空气中成像退化更严重。尤其是，光传播受到波长相关吸收和散射影响，导致对比度下降、颜色失真和空间可见性变化。这些效应破坏了一致外观和可靠特征对应等常见假设，因此给基于图像的 3D 重建带来显著挑战。

遵循常用水下成像模型，摄像机像素处的观测颜色 I_c 可以表示为衰减直接信号与后向散射光的组合：

$$I_c = J \cdot T^D + B^\infty \cdot (1 - T^B)$$

其中 J 表示真实场景 radiance， B^∞ 表示介质贡献的背景光。 T^D 和 T^B 分别对应直接分量和后向散射分量的 transmission，建模为：

$$T^D = \exp(-\beta^d \cdot z), \quad T^B = \exp(-\beta^b \cdot z)$$

其中 β^d 和 β^b 为衰减系数， z 表示场景点与相机之间的距离。

直接 transmission T^D 建模了由于视线方向上的吸收和外散射导致的场景 radiance 指数衰减，它会随着深度增加逐渐降低对比度。后向散射分量 T^B 描述悬浮粒子向相机方向散射的光，会产生 veiling effect，降低图像清晰度并遮挡细结构。波长相关衰减进一步加剧这些影响：较短波长（如蓝光）比长波长（如红光）传播更远，因此水下图像会出现典型颜色偏移。

从重建角度看，这些物理过程带来多重挑战。第一，衰减会降低远处区域的信噪比，使特征检测和匹配不可靠。第二，后向散射会引入空间变化的 haze，破坏跨视图几何一致性。第三，退化依赖深度 z ，导致场景中不同区域以不同保真度被观测。因此，标准重建方法倾向于偏向观测充分区域，而低质量区域表示不足。在 3DGS 中，纳入这些物理因素对于水下条件下的均衡表示和鲁棒重建至关重要。

图 2：所提框架流程。黄色高亮表示关键组件：（1）用于目标感知正则化的语义引导损失 L_s ；（2）在固定 primitive budget 下改善表示平衡的自适应 Gaussian primitive 重分配；（3）用于稳定训练和提高重建保真度的 stage-wise optimization。

4. 方法

整体框架如图 2 所示，新组件以黄色标出。每个 Gaussian primitive 都被扩展为带有可学习语义特征向量，该向量与从 CLIP 得到的 embedding 对齐，以引入高层上下文信息。基于区域级分割定义的语义一致性损失 L_s 提供辅助监督，促进目标级一致性，并降低冗余背景区域影响。

为解决表示不均衡，本文引入自适应 Gaussian 分配机制，将 primitive 从低贡献区域重新分配到高重建误差区域。该过程在保持固定 primitive budget 的同时，提高空间覆盖和重建保真度。此外，本文采用 stage-wise optimization 以提高训练稳定性：优化从强调全局结构的初始阶段进入强调细粒度外观的 refinement 阶段，从而在退化成像条件下得到更一致的重建。框架还包含作者前作中的 frame interpolation 策略，该策略已被证明能改善 sparse-view 场景性能。

4.1 语义引导的 Gaussians

传统 3D Gaussian Splatting 使用光度重建损失均匀优化所有 primitive，不考虑信息内容的空间差异。这一假设在水下环境中并不理想，因为散射、衰减和稀疏观测会导致视觉质量高度不均匀。因此，显著前景结构需要更高重建保真度，而退化区域提供的信号弱且不可靠，会阻碍几何一致性。

为解决该限制，本文将语义信息纳入 Gaussian 表示，实现目标感知正则化。语义引导 Gaussian 模块如图 3 所示。通过集成语义特征，框架将高层场景理解与低层退化联系起来。在浑浊条件下，单独依赖光度监督很难区分真实几何和介质导致的 artifact（如后向散射）。所提语义引导损失 L_s 通过强制同一语义区域内的 Gaussian primitives 保持特征一致，作为结构约束。例如，coral reefs 或 shipwrecks 内部应更一致。该约束会抑制向漂浮粒子或 haze 等语义不一致区域分配密度，从而提升重建几何保真度，尤其是显著目标边界附近。

在本文框架中，每个 Gaussian primitive 都被扩展为一个额外语义属性，即可学习特征向量 $f_s \in \mathbb{R}^d$ ，其中 d 为语义 embedding 空间维度。与几何和光度属性不同， f_s 在外部监督下优化，用于编码高层上下文信息，并在重建过程中实现目标感知正则化。

为获得参考语义 embedding，本文首先使用 BLIP3-o 为每个场景生成文本描述。随后，这些描述用于引导 Grounded-SAM 在输入图像 I_{img} 中识别感兴趣区域。该过程表示为：

$$R = \{R_k\}_{k=1}^K = \text{Grounded-SAM}(I_{img}, \text{BLIP3-o}(I_{img}))$$

$$I_{R_k} = I_{img}[R_k], \quad f_{ref,k} = \text{CLIP}(I_{R_k}), \quad k = 1, \dots, K$$

其中 $R = \{R_k\}_{k=1}^K$ 表示检测到的语义区域集合， R_k 表示第 k 个语义区域， I_{R_k} 表示对应裁剪图像 patch， $f_{ref,k}$ 表示从该区域提取的 CLIP embedding。实际实现中，每张图像选择固定数量区域（ $K = 3$ ），以覆盖场景中的主要语义内容。每个选定区域为投影落入该区域的 Gaussian primitives 提供区域级语义目标。

训练时，投影落在检测语义区域中的 Gaussian primitives 会通过如下损失与对应参考 embedding 对齐：

$$L_s = \sum_{i \in G_{vis}} \|f_s(i) - f_{ref, r(i)}\|_2^2$$

其中 G_{vis} 表示分配到语义区域中的可见 Gaussian primitive 集合， $r(i)$ 表示第 i 个 Gaussian 投影对应的语义区域索引。因此 $f_{ref, r(i)}$ 是分配给第 i 个 Gaussian 的参考语义 embedding， $f_s(i)$ 表示第 i 个 Gaussian primitive G_i 的可学习语义特征。对于重叠区域，采用确定性的 first-match rule；未被任何区域覆盖的 Gaussian 不参与语义监督。该损失按 view-dependent 方式应用，因此可见性和遮挡由标准 3DGS 渲染流程隐式处理。

语义项被设计为辅助正则，而不是主监督信号。为此，区域分配和目标 embedding 在优化期间保持固定，语义特征也不直接参与渲染过程。这一设计缓解了水下图像中常见的噪声或不完美语义线索带来的影响，并保证任何优化仍主要由光度一致性驱动，同时受益于额外语义引导。这种监督通过鼓励同一区域内 Gaussian primitive 具有相似语义特征，促进语义-几何一致性，从而在噪声、低可见性或 sparse-view 条件下支持目标级一致性，并改善光度线索退化区域的重建一致性。最终，重建场景表现出更好的结构一致性和感知质量。

图 3：所提语义引导 Gaussian 模块概览。BLIP3-o 和 Grounded-SAM 用于提取语义区域；随后从这些区域中得到基于 CLIP 的特征，用于监督对应 Gaussian primitive 的可学习语义特征。

4.2 自适应 Gaussian primitive 重分配

现有基于 3DGS 的方法使用梯度驱动 densification，即利用位置梯度在优化过程中引入额外 Gaussian primitives。虽然这种策略可以改善局部细节，但也会导致表示冗余，并可能限制整体重建质量。为解决该问题，本文提出自适应 Gaussian primitive 重分配策略，将 primitive 从低贡献区域迁移到高重建误差区域，以提高表示效率和空间覆盖。

类似 Speedy-Splat，本文根据每个 Gaussian primitive 对渲染图像的贡献定义重要性分数 $\tilde{S}_i$ ：

$$\tilde{S}_i = \log |\nabla_{I_G} g_i \nabla_{I_G} g_i^T|$$

其中 I_G 表示由所有 Gaussians 形成的渲染图像， $\nabla_{I_G} g_i$ 表示第 i 个 Gaussian 对 I_G 贡献的梯度。由于 g_i 为标量且对数函数单调递增，重要性分数可简化为：

$$\tilde{S}_i = (\nabla_{I_G} g_i)^2$$

它衡量渲染图像对每个 Gaussian primitive 的敏感程度。 $\tilde{S}_i$ 越高，表示对应 primitive 对渲染图像影响越大。

为进一步提高重建质量，本文定义误差分数 $\tilde{E}_i$ ，用于量化每个 Gaussian primitive 对重建损失 L_{Rec} 的贡献：

$$\tilde{E}_i = (\nabla_{L_{Rec}} g_i)^2$$

其中 $\nabla_{L_{Rec}} g_i$ 表示第 i 个 Gaussian 贡献相对于重建损失的梯度。

在 densification 阶段后，本文周期性评估重要性分数 $\tilde{S}_i$ 和误差分数 $\tilde{E}_i$ （本文每 3000 次迭代一次）。基于 $\tilde{S}_i$ ，移除分数最低的一部分 primitive（bottom 10%），因为它们对渲染输出贡献最小。对应 budget 通过 cloning 操作重新分配给误差分数最高的 primitive（按 $\tilde{E}_i$ 排名前 10%）。新 primitive 以被选中高误差 Gaussian 的相同属性初始化，并在随后的优化中进一步细化以捕获局部结构。剪枝和克隆比例为启发式设定；实际中，在合理范围内性能稳定，消融实验也展示了持续改进。

图 4 展示了自适应 Gaussian 重分配过程（下分支）相对标准 densification（上分支）的效果。在 densification 停止后，每 3000 次迭代开始重分配，先剪去 10% 低重要性 primitive。由于表示容量临时下降，剪枝会使重建质量略微降低（示例中约 0.02 dB）。随后，重分配过程将释放出的 primitive 转移到更高重建误差区域，得到

更均衡的空间分布。对应 normalized density map（由投影 opacity α_i 得到）显示了更均匀覆盖。经过进一步优化后，相比无重分配情况，重建质量显著提升；图 4 右侧结果显示，之前的高误差区域在 Gaussian 重分配后表现出更清晰结构细节。

总体而言，自适应重分配策略是一种动态密度管理机制，通过将容量从低贡献区域转移到高重建误差区域，提高表示效率。它缓解了梯度驱动 densification 引入的不均衡，减少冗余并缓解过拟合，同时在整个优化过程中保持固定数量的 Gaussian primitives，从而保留实时渲染所需的计算效率。

图 4： 不使用（上）和使用（下）自适应 Gaussian primitive 重分配过程的重建结果对比。重分配得到更均衡的 primitive 空间分布，并在优化后提升 PSNR。normalized density map 中较暗区域表示较低 Gaussian density。

4.3 Stage-wise optimization 策略

为提高优化稳定性和重建质量，本文采用两阶段从粗到细训练策略。

Stage 1（重建阶段）： 关注全局几何与外观的联合优化。Stage 1 的损失以基于 L1 的 reconstruction term 和 SSIM 为主，对噪声更鲁棒。其他损失项用于保留结构一致性并建模水下成像物理，包括 depth alignment、medium-related regularization、edge smoothness、semantic alignment，以及一个较小的 L2 项。该阶段促进在退化观测下鲁棒恢复全局场景结构。

Stage 2（细化阶段）： 冻结几何和语义 Gaussian 参数，包括 position f_{xyz} 、rotation $f_{rotation}$ 、scale f_{scale} 和 semantic feature f_s ，重点进行外观细化。具体而言，外观相关参数继续优化；semantic、depth 和 smoothness 正则项被禁用；SSIM 项被移除；并在该阶段强调 L2 reconstruction term，以增强细节和颜色一致性。

这种 stage-wise optimization 方案提高了噪声和 sparse-view 条件下的收敛性，降低了对介质退化的敏感性，并在困难水下场景中得到更一致的重建质量。实验中，前 60% 迭代作为重建阶段，最后 40% 作为细化阶段。该划分是实用启发式设置，最优切换点可能随数据集和场景特性变化。

4.4 损失函数

训练过程遵循上述两阶段优化计划，并由复合目标函数引导。baseline losses 采用作者前作中的 reconstruction loss L_{Rec} 、depth supervision L_{Depth} 、gray-world prior L_g 和 edge-aware smoothness L_{Smooth} 。为改善稳定性和外观建模，本文引入额外损失项，包括语义损失 L_s 、用于细化外观的 pixel-wise mean squared error 项 L_2 ，以及约束预测衰减系数 β^d 和 β^b 的 hinge loss L_h 。

总体目标函数为：

$$L_{final} = L_{Rec} + L_{Depth} + L_g + L_{Smooth} + \lambda_s L_s + \lambda_2 L_2 + \lambda_h L_h$$

其中 λ_s 、 λ_2 和 λ_h 分别控制 semantic、mean square error 和 hinge 项的贡献。对于插值帧，采用 uncertainty-weighted 公式：

$$L'_{final} = \frac{1}{2}\gamma L_{final} - \frac{1}{2}\zeta \log(\gamma)$$

其中 γ 表示学习到的不确定性， ζ 是正则化系数。

4.4.1 基础损失

L_{Rec} ：重建损失结合了对 outlier 鲁棒的 mean absolute error 项和结构相似性 SSIM 项：

$$L_{Rec} = \lambda_1(1 - \lambda_r)\|I_{out} - I_{gt}\|_1 + \lambda_r(1 - SSIM(I_{out}, I_{gt}))$$

其中 $\lambda_1 = 0.7 + 0.5 \cdot (iteration/iterations)$, λ_r 控制 SSIM 项贡献。具体而言, Stage 1 中 $\lambda_r = 0.2$, Stage 2 中 $\lambda_r = 0$ 。

L_{Depth} : 深度 z 很重要, 因为它用于估计水下介质参数。因此引入深度监督项:

$$L_{Depth} = \lambda_d \|\hat{D} - D\|_1 + \lambda_{ca} \sum_{ch \in \{r, g, b\}} \sum_{n \in \{d, b\}} \|z_n^{ch} - D\|_1$$

其中 λ_d 和 λ_{ca} 在 Stage 1 中分别设置为 0.1 和 1, 在 Stage 2 中都为 0。 D 表示参考深度, $\hat{D}$ 表示渲染深度。由于缺少 ground-truth depth, 本文使用 Depth Anything V2 估计的 pseudo-depth 进行监督。 z_n^{ch} 表示每个颜色通道 ch 在 direct ($n = d$) 和 backscatter ($n = b$) 分量下推断的深度。

L_g : gray-world prior 应用于水下退化前估计的场景 radiance, 强制 RGB 通道平均强度近似相等。目标值 0.5 对应 gray-world 假设下理想的平衡强度, 用于防止模型收敛到不合理颜色偏移。损失定义为:

$$L_g = \sum_{ch \in \{r, g, b\}} (\mu(J_{ch}) - 0.5)^2$$

其中 J_{ch} 表示归一化到 $[0, 1]$ 范围的通道 ch 恢复像素值, $\mu(\cdot)$ 表示每个通道的平均强度。

L_{Smooth} : 该项惩罚与图像边缘不一致的深度不连续, 即允许颜色边缘处存在尖锐深度边缘, 但惩罚平滑区域中的漂浮或噪声深度。edge-aware smoothness loss 定义为:

$$L_{Smooth} = \lambda_m \sum_{i,j} [\exp(-\lambda_b |\Delta_x D_{i,j}|) |\Delta_x I_{i,j}| + \exp(-\lambda_b |\Delta_y D_{i,j}|) |\Delta_y I_{i,j}|]$$

其中 (i, j) 表示图像平面空间坐标, I 为输入图像, D 为 pseudo-depth map。 $\Delta_x D_{i,j}$ 和 $\Delta_y D_{i,j}$ 分别表示深度图在水平和垂直方向的前向差分; $\Delta_x I_{i,j}$ 和 $\Delta_y I_{i,j}$ 为对应图像梯度。本文固定 $\lambda_b = 5$, λ_m 在 Stage 1 中为 0.05, 在 Stage 2 中为 0。

4.4.2 额外损失

本节描述本文新增的三个损失项。

L_s : 语义损失如前述公式定义。其权重系数 λ_s 在 Stage 1 中随训练调度:

$$\lambda_s = \max(0.01, 0.3 \cdot (1 - iteration/iterations))$$

这使得优化早期 (建立全局结构时) 权重较高, 并随训练推进逐渐降低影响。Stage 2 中禁用语义损失 ($\lambda_s = 0$), 以便在没有额外语义约束的情况下进行细粒度外观细化。

L_2 : mean squared error 项用于增强对高频细节和高对比区域的敏感性。在 Stage 1 中, 它被赋予低权重, 并按 $0.1 \cdot iteration/iterations$ 逐渐增加。Stage 2 中, 其贡献提高到 0.9, 以支持细粒度外观细化。这一从 L1 主导到 L2 主导的转变, 反映了在几何稳定后, 从全局结构学习转向精确颜色和细节重建。

L_h : hinge 项作为弱正则 ($\lambda_h = 0.001$), 鼓励不同颜色通道衰减具有一致排序, 反映典型水下成像行为, 同时避免严格物理约束。由于系数按场景估计, 本文只约束相对排序, 使其可适应不同环境条件。

对于期望不等式 $a > b$, hinge loss 定义为:

$$L_{hinge}(a, b) = \max(0, b - a + m)$$

其中 $m \geq 0$ 为小 margin (设置为 10^{-3})。约束满足时损失为零, 违反时线性增加。

根据水下光传播的波长相关衰减规律，长波长比短波长衰减更快，因此对衰减系数施加排序约束 $\beta_r^* > \beta_g^* > \beta_b^*$ ，其中 $*$ $\in \{d, b\}$ 。实现为：

$$L_h^* = \max(0, \beta_g^* - \beta_r^* + m) + \max(0, \beta_b^* - \beta_g^* + m)$$

下标表示 RGB 通道。虽然该排序反映了清水中的典型衰减行为，但在某些环境（如富含 chlorophyll 的近岸水域）中可能存在偏差，并可直接调整。因此，hinge 项作为弱正则，而非严格约束。最终 hinge loss 定义为：

$$L_h = \frac{1}{2}(L_h^d + L_h^b)$$

实践中，作者发现将 L_h 集成到优化中可使渲染质量约提升 0.066 dB。同时，它也改善训练稳定性，这可从总训练损失，尤其是 L_{Rec} 中观察到。

图 5：SeaThru-NeRF 数据集中每个场景的示例图像。

图 6：Submerged3D 数据集中每个场景的示例图像。

图 7：S-UW 数据集中每个场景的示例图像。

5. 数据集

本文在三个公开真实世界水下数据集上评估所提方法：SeaThru-NeRF、Submerged3D 和 S-UW。这些数据集展现出不同水下图像特性，为评估 3D 重建方法的鲁棒性和泛化能力提供互补测试条件。所有图像均 resize 到 720p 分辨率，以保证实验一致性。

SeaThru-NeRF 包含四个场景，采集自三个海洋环境，包括 Red Sea（IUI3-RedSea 和 Japanese-RedSea）、Caribbean Sea（Curaçao）以及 Pacific Ocean（Panama）。这些场景分别包含 20、20 和 18 张 RGB 图像，每个场景保留 3 张用于验证。该数据集覆盖一系列水下成像条件和场景复杂度。如图 5 所示，所有场景都描绘 coral reef 环境，可见性和照明变化相对有限。

Submerged3D 包含四个场景：Guam 附近的 SMS Cormoran 和 Tokai Maru shipwreck，Mellu Island 附近 Kwajalein Atoll 的 F4U-1 Corsair wreck，以及 Canary Islands 附近的 SS America (Isro)。每个场景来自更大数据集，从中选择 20 张 720p RGB 图像进行处理。数据由 National Park Service Submerged Resources Center 提供。由于 sparse viewpoints、低光照条件和严重图像退化，该数据集对 3D 重建非常困难。示例场景如图 6 所示。评估时，本文沿用预定义 split：每第八张图像分配到测试集，其余用于训练。

S-UW 包含四个场景，采集于泰国 Krabi 群岛附近，每个场景包含 24 张 RGB 图像。该数据集采集于浅水环境，包含动态水面运动引起的明显 flickering（如图 7 所示）。场景主要由纹理丰富的 coral reef 结构构成，一些序列还包含移动鱼类，因非刚性运动而带来额外复杂性。

表 1： SWAGSplatting 与六个 baseline（Instant-NGP、SeaThru-NeRF、3DGS、WaterSplatting、UW-GS、RUSplatting）在 SeaThru-NeRF、S-UW 和 Submerged3D 三个数据集上的性能比较。↑ 表示数值越高越好，↓ 表示数值越低越好。

表 1a：SeaThru-NeRF 结果

PSNR ↑

Method	Curacao	Panama	IUI-Redsea	Japanese-Redsea	Average
Instant-NGP	27.9215	23.4341	20.6162	23.2061	23.7945
SeaThru-NeRF	29.9162	26.9634	25.4989	21.8631	26.0604
3DGS	29.0234	30.7038	25.2240	22.3902	26.8353
WaterSplatting	31.4616	31.5367	22.1392	24.4323	27.3925
UW-GS	29.9721	31.0023	28.5473	23.5013	28.2558
RUSplatting	30.9557	31.8683	29.8036	24.5436	29.2928

Method	Curacao	Panama	IUI-Redsea	Japanese-Redsea	Average
Ours	33.0521	32.0630	30.3602	24.3617	29.9593

SSIM ↑

Method	Curacao	Panama	IUI-Redsea	Japanese-Redsea	Average
Instant-NGP	0.7013	0.6294	0.5594	0.6371	0.6318
SeaThru-NeRF	0.8463	0.7261	0.7934	0.7569	0.7807
3DGS	0.9127	0.7606	0.9005	0.8638	0.8594
WaterSplatting	0.9256	0.9213	0.6598	0.8834	0.8475
UW-GS	0.9220	0.9335	0.9243	0.8625	0.9106
RUSplatting	0.9318	0.9339	0.9292	0.8706	0.9164
Ours	0.9481	0.9389	0.9306	0.8861	0.9260

LPIPS ↓

Method	Curacao	Panama	IUI-Redsea	Japanese-Redsea	Average
Instant-NGP	0.3961	0.4361	0.6121	0.3294	0.4434
SeaThru-NeRF	0.2984	0.3684	0.3684	0.3243	0.3399
3DGS	0.1790	0.1560	0.1970	0.1960	0.1820
WaterSplatting	0.1560	0.1445	0.2984	0.1494	0.1871
UW-GS	0.1770	0.1432	0.1885	0.1916	0.1751
RUSplatting	0.1611	0.1396	0.1847	0.1809	0.1666
Ours	0.1428	0.1264	0.1822	0.1772	0.1571

表 1b: Submerged3D 结果

PSNR ↑

Method	Cormoran	Isro	Kwaj	Tokai	Average
Instant-NGP	19.5271	20.1861	18.1444	18.2488	19.0266
SeaThru-NeRF	16.8816	21.5887	20.7094	17.6072	19.1967
3DGS	20.4698	22.8198	24.0964	23.2345	22.6551
WaterSplatting	21.0749	26.2920	27.8613	23.1047	24.5832
UW-GS	20.6942	24.6752	28.4065	23.5880	24.3410
RUSplatting	21.9625	27.8693	28.9058	24.4585	25.7990
Ours	21.9794	28.1544	28.8320	25.6028	26.1422

SSIM ↑

Method	Cormoran	Isro	Kwaj	Tokai	Average
Instant-NGP	0.5055	0.6588	0.4682	0.4082	0.5102
SeaThru-NeRF	0.4533	0.6501	0.5116	0.3720	0.4968
3DGS	0.6756	0.8421	0.8485	0.6517	0.7545
WaterSplatting	0.6482	0.8517	0.8709	0.6362	0.7518
UW-GS	0.6800	0.8649	0.8868	0.6578	0.7724
RUSplatting	0.6846	0.8680	0.8774	0.6599	0.7725
Ours	0.7023	0.8782	0.8847	0.7391	0.8011

LPIPS ↓

Method	Cormoran	Isro	Kwaj	Tokai	Average
Instant-NGP	0.5505	0.4146	0.4535	0.5723	0.4977
SeaThru-NeRF	0.6118	0.5025	0.5240	0.6360	0.5686
3DGS	0.3852	0.3008	0.2276	0.4017	0.3288
WaterSplatting	0.3846	0.2716	0.2162	0.3965	0.3172
UW-GS	0.3412	0.2683	0.2105	0.3833	0.3008
RUSplatting	0.3662	0.2670	0.2253	0.3548	0.3033
Ours	0.3482	0.2643	0.2161	0.3612	0.2974

表 1c: S-UW 结果

PSNR ↑

Method	Lagoon	Marine	Reef	Seabed	Average
Instant-NGP	21.6674	15.7300	18.5866	19.6167	18.9002
SeaThru-NeRF	25.5424	18.1031	18.5510	22.7050	21.2254
3DGS	27.1166	18.9492	22.4663	26.4933	23.7564
WaterSplatting	27.1979	19.6173	26.6378	26.0623	24.8788
UW-GS	26.9103	20.0065	23.3078	26.5088	24.1834
RUSplatting	27.6000	20.9329	26.7588	27.0903	25.5955
Ours	27.5294	20.7229	26.8547	27.4631	25.6425

SSIM ↑

Method	Lagoon	Marine	Reef	Seabed	Average
Instant-NGP	0.5480	0.4637	0.4382	0.4275	0.4694
SeaThru-NeRF	0.7592	0.5718	0.4077	0.6407	0.5949
3DGS	0.8707	0.6922	0.7117	0.8234	0.7745
WaterSplatting	0.8685	0.6869	0.7971	0.8136	0.7915
UW-GS	0.8736	0.7145	0.7277	0.8197	0.7839
RUSplatting	0.8659	0.7447	0.8154	0.8292	0.8138
Ours	0.8659	0.7328	0.8127	0.8370	0.8121

LPIPS ↓

Method	Lagoon	Marine	Reef	Seabed	Average
Instant-NGP	0.3198	0.4410	0.5058	0.3198	0.3966
SeaThru-NeRF	0.2860	0.4582	0.5522	0.3455	0.4105
3DGS	0.1606	0.2990	0.2646	0.1684	0.2232
WaterSplatting	0.1135	0.2619	0.1769	0.1516	0.1760
UW-GS	0.1479	0.2678	0.2504	0.1541	0.2051
RUSplatting	0.1719	0.2706	0.2222	0.1771	0.2105
Ours	0.1625	0.2764	0.2124	0.1553	0.2017

图 8: novel view rendering 对比。第一行显示 SeaThru-NeRF 数据集 IUI-Redsea 场景结果，第二行显示 Submerged3D 数据集 Isro 场景重建结果。第三行左侧显示 Japanese-Redsea 重建场景，右侧显示 Submerged3D 的 Tokai。第四行是 S-UW 数据集结果，分别显示 Reef（左）和 Seabed（右）的重建场景。

6. 实验与结果

6.1 实验设置

所有实验均在单块 NVIDIA RTX 4090 GPU 上进行。本文使用 COLMAP 初始化点云并估计图像序列的相机位姿。作者修改原始 3DGS 使用的 diff-gaussian-rasterization 模块，使其可以渲染 depth maps，并在 backward pass 中加入额外梯度计算分支用于 depth loss L_{Depth} 。

超参数 λ_h 固定为 1×10^{-3} ，而 λ_s 和 λ_2 在训练期间动态调度。具体而言， λ_s 从 0.3 衰减到 0.01，然后在 fine-tuning 阶段设置为 0； λ_2 从 0 线性增加到 0.1，然后在 fine-tuning 阶段设置为 0.9。为了估计 3DGS 参数，本文使用五层 MLP，该选择基于超参数敏感性分析。

每个模型训练 20,000 次迭代，第二优化阶段从第 12,000 次迭代开始。为提高计算效率，参考语义 embedding $\{f_{ref,k}\}_{k=1}^K$ 在训练开始时预计算并缓存复用。投影 CLIP embedding 空间维度设置为 $d = 32$ 。对于 frame interpolation，本文按照 RUSplatting 采用 Real-Time Intermediate Flow Estimation (RIFE)。使用固定权重因子 0.1 替代自适应加权，在不同数据集上提供重建准确性和插值质量之间的稳定折中。实践中，作者在一定范围内观察到稳定收敛；当任一项被移除时性能下降，说明两个模块都有贡献。

本文将所提方法与六个代表性 baseline 比较：Instant-NGP、SeaThru-NeRF、3DGS、WaterSplatting、UW-GS 和 RUSplatting。部分近期方法（Aquatic-GS、RecGS、R-Splatting、AtlantisGS）由于未公开代码，因此未纳入比较。虽然 SeaSplat 提供官方代码，但作者在推荐设置下观察到训练中的数值不稳定，因此也将其排除。

为了公平评估，所有 baseline 均使用官方代码库实现，并在相同图像序列和优化设置下训练，遵循相同 dataset split protocol。损失权重采用前人工作设置，以保证比较公平。

图 9：从输入图像使用 COLMAP 生成点云的工作流。初始点云在一些区域噪声明显且稀疏。训练后，用于 novel view rendering 的点云更干净。图中展示了每个 3D 点的 ellipsoid，说明它们如何用于生成最终渲染结果。

6.2 定量比较

定量性能使用三个标准指标评估：Peak Signal-to-Noise Ratio (PSNR)、Structural Similarity Index Measure (SSIM) 和 Learned Perceptual Image Patch Similarity (LPIPS)，分别衡量像素级准确性、结构相似性和感知质量。

表 1 展示了所提方法与六个 baseline 在三个数据集上的定量比较。跨所有数据集平均来看，所提方法在三个指标上均取得最佳性能，说明其在重建准确性和感知质量方面都有持续改进。

在 SeaThru-NeRF 数据集上，本文方法优于最强 baseline RUSplatting，平均 PSNR 提升 0.67 dB，SSIM 提升 1.05%，LPIPS 降低 5.70%。值得注意的是，所有场景都有提升，表明该方法在不同水体条件下具有鲁棒性能。

在更具挑战性的 Submerged3D 数据集上，由于存在 sparse viewpoints 和严重图像退化，所提方法仍然优于已有方法。与 UW-GS 相比，它平均 PSNR 提升 1.80 dB，SSIM 提升 3.72%，LPIPS 降低 1.13%。这些增益说明该方法能有效处理低可见性和 sparse-view 场景。

在 S-UW 数据集的四个场景上，本文方法在 PSNR 上取得最佳平均性能 (25.6425 dB)，同时 SSIM (0.8121) 和 LPIPS (0.2017) 具有竞争力。强 PSNR 结果可能源于优化策略的 Stage 2，其中强调了 L2 项。需要注意，不同方法表现出不同 trade-off。例如 WaterSplatting 得到最低平均 LPIPS，说明其感知相似性更强；RUSplatting 在部分场景中取得较高 SSIM 和较强 PSNR。相比之下，本文方法在所有指标和场景上表现更平衡，未在特定设置中明显退化。这种一致性对于 S-UW 的浅水场景尤其重要，因为 flickering 和非刚性运动带来额外挑战。

总体而言，这些结果证明了语义引导、stage-wise optimization 和 Gaussian 重分配策略在困难水下条件下提升结构一致性和感知质量的有效性，覆盖从相对受控的 reef 环境到高度退化的深海场景。

表 2：SeaThru-NeRF、Submerged3D 和 S-UW 所有场景平均后的消融结果。SG 表示 Semantic-guided Gaussians；SO 表示 Stage-wise optimization；AR 表示 Adaptive Gaussian primitives reallocation。

Variant	SG	SO	AR	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$
M1	否	是	是	27.4453	0.8373	0.2426
M2	是	否	是	27.8131	0.8511	0.2355
M3	是	是	否	27.8604	0.8632	0.2297
Ours	是	是	是	28.0508	0.8636	0.2272

6.3 定性比较

图 8 中的定性结果展示了所提方法相较于已有方法的视觉性能。baseline 方法在重建精细几何结构和维持背景一致性方面存在明显限制，尤其是在受到散射和低可见性影响的区域（图中第一行来自 SeaThru-NeRF 数据集的黄色和红色高亮区域）。例如，若干方法无法恢复珊瑚细小尖刺结构，或产生不一致背景纹理。相比之下，所提方法保留了这些复杂细节，得到更锐利、更忠实的重建。

对于 Submerged3D 数据集，图 8 第二行显示本文方法实现了更高几何准确性和更一致的颜色表示，而竞争方法出现可见 artifact（如 RUSplatting）或模糊结构（如 UW-GS）。第三行进一步确认了本文方法在困难场景中保持细结构和感知质量的优势。第四行展示 S-UW 数据集结果。虽然表 1 的定量结果显示 RUSplatting 获得最佳 PSNR，但定性结果表明，当跨视图照明变化时，它难以准确重建内容。尽管 WaterSplatting 取得最佳感知质量指标（LPIPS），其结果虽然看起来比 SWAGSplatting 更锐利，但也引入了 artifact，如裁剪区域所示。总体而言，结果表明本文方法在多样水下条件下生成更一致且视觉上更连贯的重建。

图 9 展示了 3D 渲染工作流。图中可见，COLMAP 重建包含明显噪声和不规则点分布，尤其是在低可见性和散射影响区域。这些 artifact 来自困难水下条件下不可靠的特征匹配和不准确的深度估计。相比之下，本文方法优化后的点云更连贯且空间一致。噪声明显减少，结构细节得到更好保留，形成更干净、更完整的场景表示。这表明在退化水下环境中，本文方法比传统摄影测量方法生成更高质量几何表示；后者通常还需要过滤 outlier 和噪声，以及可选的 downsampling 或数据清理，才能得到可用重建。

图 10： 语义引导示例。从左到右依次为输入场景、生成描述和 segmentation maps。

6.4 消融实验

为了评估所提框架中各组件的贡献，本文进行了消融实验，配置和结果总结于表 2。从完整模型出发，移除任一单独组件都会导致所有指标一致下降，说明每个模块都对整体重建质量有正向贡献。

其中，移除语义引导（M1）带来最大性能下降。这突出了语义模块作为感知级正则器的作用：它不依赖显式类别标签，也能改善区域级一致性。通过利用 CLIP embedding，语义相似区域被鼓励呈现一致表示，从而稳定那些光度线索模糊或退化区域的重建。图 10 展示了生成描述及其对应语义分割图示例。由于带标注水下数据集有限，评估基于既有 benchmark，因此结论限定于这些条件下的重建性能。

Variant M2 移除 stage-wise optimization，但保留语义引导和 Gaussian 重分配。如果没有分阶段训练，模型会在整个训练过程中同时优化几何和外观，这可能导致不稳定和次优细化，尤其是在退化成像条件下。完整模型中的 stage-wise 策略有助于将全局结构学习与细粒度外观优化解耦，从而实现更稳定收敛和更高重建保真度。

移除自适应 Gaussian 重分配组件（M3）会导致相对较小的性能下降。这符合预期，因为重分配机制主要通过将 primitive 从低贡献区域转移到高重建误差区域来提高表示效率。其影响更局部（如图 4 所示），因此在固定 primitive budget 下，对场景级平均指标的影响不如语义引导显著。

总体来看，完整模型取得最佳性能，说明所提组件组合后提供了互补收益。

7. 结论

本文提出一种用于水下场景重建的语义引导 3D Gaussian Splatting 框架。所提方法为每个 Gaussian primitive 扩展可学习语义特征，并使用基于 CLIP 的 embedding 进行监督，以促进语义-几何一致性。本文引入语义损失，用于鼓励保留高层结构关系，从而改善感知质量。此外，采用 stage-wise optimization 提高训练稳定性，并提出自适应 Gaussian 重分配机制，在固定 budget 内通过重新分配 primitive 提高表示效率。这些组件共同使模型能够在困难水下条件下实现更一致、更细致的重建。实验结果表明，所提方法在多个 benchmark 上实现了更优性能。代码将在论文接收后发布。

CRediT 作者贡献声明

Zhuodong Jiang: Writing - review & editing, Writing - original draft, Visualization, Validation, Methodology, Data curation, Conceptualization.

Haoran Wang: Writing - review & editing, Writing - original draft, Visualization, Validation, Methodology, Conceptualization.

Guoxi Huang: Writing - review & editing, Methodology.

Brett Seymour: Data curation, Resources.

Nantheera Anantrasirichai: Writing - review & editing, Methodology, Conceptualization, Supervision, Resources, Project administration, Funding acquisition.

利益冲突声明

作者声明不存在任何已知竞争性经济利益或个人关系，可能影响本文所报告的工作。

致谢

本工作受到 UKRI MyWorld Strength in Places Programme (SIPF00006/1) 和 EPSRC ECR (EP/Y002490/1) 支持。

参考文献

参考文献条目保留原论文英文格式，便于与原文引用、BibTeX 和 DOI 对齐。

Akkaynak, D., Treibitz, T., 2018. A revised underwater image formation model, in: IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 6723-6732. doi:10.1109/CVPR.2018.00703.

Akkaynak, D., Treibitz, T., 2019. Sea-thru: A method for removing water from underwater images, in: IEEE Conference on Computer Vision and Pattern Recognition, pp. 1682-1691.

Bekerman, Y., Avidan, S., Treibitz, T., 2020. Unveiling optical properties in underwater images, in: 2020 IEEE International Conference on Computational Photography (ICCP), pp. 1-12. doi:10.1109/ICCP48838.2020.9105267.

Bryson, M., Johnson-Roberson, M., Pizarro, O., Williams, S.B., 2016. True color correction of autonomous underwater vehicle imagery. *Journal of Field Robotics* 33, 853-874.

Burns, J.H.R., Delparte, D., 2017. Comparison of commercial structure-from-motion photogrammetry software used for underwater three-dimensional modeling of coral reef environments. *International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences XLII-2/W3*, 127-131. doi:10.5194/isprs-archives-XLII-2-W3-127-2017.

Chen, J., Xu, Z., Pan, X., Hu, Y., Qin, C., et al., 2025. Blip3-o: A family of fully open unified multimodal models-architecture, training and dataset. arXiv:2505.09568.

Chen, L., Xiong, Y., Zhang, Y., Yu, R., Fang, L., Liu, D., 2024. Sp-seanerf: Underwater neural radiance fields with strong scattering perception. *Computers & Graphics* 123, 104025.

Elnashef, B., Filin, S., 2023. A three-point solution with scale estimation ability for two-view flat-refractive underwater photogrammetry. *ISPRS Journal of Photogrammetry and Remote Sensing* 198, 223-237. doi:https://doi.org/10.1016/j.isprsjprs.2023.03.015.

Fang, G., Wang, B., 2024. Mini-splatting: Representing scenes with a constrained number of gaussians, in: European Conference on Computer Vision (ECCV), pp. 165-181.

Gough, L., Azzarelli, A., Zhang, F., Anantrasirichai, N., 2025. AquaNeRF: Neural radiance fields in underwater media with distractor removal, in: ISCAS.

Hanson, A., Tu, A., Lin, G., Singla, V., Zwicker, M., Goldstein, T., 2025. Speedy-splat: Fast 3d gaussian splatting with sparse pixels and sparse primitives, in: Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR), pp. 21537-21546.

- Heshmat, M., Saad Saoud, L., Abujabal, M., Sultan, A., Elmezain, M., Seneviratne, L., Hussain, I., 2025. Underwater slam meets deep learning: Challenges, multi-sensor integration, and future directions. *Sensors* 25. doi:10.3390/s25113258.
- Hu, K., Wang, T., Shen, C., Weng, C., Zhou, F., Xia, M., Weng, L., 2023. Overview of underwater 3d reconstruction technology based on optical images. *Journal of Marine Science and Engineering* 11. URL: <https://www.mdpi.com/2077-1312/11/5/949>, doi:10.3390/jmse11050949.
- Huang, B., Liu, Z., Wong, N., 2025a. Decomposing densification in gaussian splatting for faster 3d scene reconstruction. *arXiv preprint arXiv:2507.20239*.
- Huang, G., Wang, H., Qi, Z., Lu, W., Bull, D., Anantrasirichai, N., 2025b. From restoration to reconstruction: Rethinking 3D gaussian splatting for underwater scenes. *arXiv:2509.17789*.
- Huang, G., Wang, H., Seymour, B., Kovacs, E., Ellerbrock, J., Blackham, D., Anantrasirichai, N., 2025c. Visual enhancement and 3d representation for underwater scenes: A review. *arXiv preprint arXiv:2505.01869*.
- Huang, Z., Zhang, T., Heng, W., Shi, B., Zhou, S., 2022. Real-time intermediate flow estimation for video frame interpolation, in: *European Conference on Computer Vision*, Springer. pp. 624-642.
- Jiang, Z., Wang, H., Huang, G., Seymour, B., Anantrasirichai, N., 2025. RUSplatting: Robust 3d gaussian splatting for sparse-view underwater scene reconstruction, in: *BMVC*.
- Kerbl, B., Kopanas, G., Leimkuehler, T., Drettakis, G., 2023. 3D gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics* 42. URL: <https://repo-sam.inria.fr/fungraph/3d-gaussian-splatting/>.
- Levy, D., Peleg, A., Pearl, N., Rosenbaum, D., Akkaynak, D., Korman, S., Treibitz, T., 2023. Seathru-nerf: Neural radiance fields in scattering media, in: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*, pp. 56-65.
- Li, H., Song, W., Xu, T., Elsig, A., Kulhanek, J., 2025. WaterSplatting: Fast underwater 3D scene reconstruction using gaussian splatting, in: *International Conference on 3D Vision (3DV)*.
- Liu, S., Lu, J., Gu, Z., Li, J., Deng, Y., 2024. Aquatic-GS: A hybrid 3d representation for underwater scenes. *arXiv:2411.00239*.
- Mildenhall, B., Srinivasan, P.P., Tancik, M., Barron, J.T., Ramamoorthi, R., Ng, R., 2021. NeRF: Representing scenes as neural radiance fields for view synthesis. *Communications of the ACM* 65, 99-106.
- Muller, T., Evans, A., Schied, C., Keller, A., 2022. Instant neural graphics primitives with a multiresolution hash encoding. *ACM Transactions on Graphics* 41, 1-15.
- Radford, A., Kim, J.W., Hallacy, C., Ramesh, A., et al., 2021. Learning transferable visual models from natural language supervision, in: *International Conference on Machine Learning (ICML)*, pp. 8748-8763.
- Ramazzina, A., Bijelic, M., Walz, S., Sanvito, A., Scheuble, D., Heide, F., 2023. Scatternerf: Seeing through fog with physically-based inverse neural rendering, in: *International Conference on Computer Vision (ICCV)*, pp. 17957-17968.
- Ren, T., Liu, S., Zeng, A., Lin, J., Li, K., Cao, H., Chen, J., Huang, X., Chen, Y., Yan, F., et al., 2024. Grounded SAM: Assembling open-world models for diverse visual tasks. *arXiv preprint arXiv:2401.14159*.
- Schonberger, J.L., Frahm, J.M., 2016. Structure-from-motion revisited, in: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*, pp. 4104-4113.
- Sethuraman, A.V., Ramanagopal, M.S., Skinner, K.A., 2023. WaterNeRF: Neural radiance fields for underwater scenes, in: *OCEANS*.
- She, M., Nakath, D., Song, Y., Koeser, K., 2022. Refractive geometry for underwater domes. *ISPRS Journal of Photogrammetry and Remote Sensing* 183, 525-540. doi:<https://doi.org/10.1016/j.isprsjprs.2021.11.006>.
- Song, Y., She, M., Koeser, K., 2024. Advanced underwater image restoration in complex illumination conditions. *ISPRS Journal of Photogrammetry and Remote Sensing* 209, 197-212. doi:<https://doi.org/10.1016/j.isprsjprs.2024.02.004>.

- Sun, K., Cui, W., Chen, C., 2021. Review of underwater sensing technologies and applications. *Sensors* 21. doi:10.3390/s21237849.
- Tang, Y., Zhu, C., Wan, R., Xu, C., Shi, B., 2024. Neural underwater scene representation, in: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*, pp. 11780-11789.
- Treibitz, T., Schechner, Y., Kunz, C., Singh, H., 2012. Flat refractive geometry. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 34, 51-65. doi:10.1109/TPAMI.2011.105.
- Wang, H., Anantrasirichai, N., Zhang, F., Bull, D., 2025. UW-GS: Distractor-aware 3D gaussian splatting for enhanced underwater scene reconstruction, in: *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pp. 3280-3289.
- Wang, H., Huang, G., Zhang, F., Bull, D., Anantrasirichai, N., 2026. Prune wisely, reconstruct sharply: Compact 3d gaussian splatting via adaptive pruning and difference-of-gaussian primitives, in: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- Yang, D., Leonard, J.J., Girdhar, Y., 2025. Seasplat: Representing underwater scenes with 3D gaussian splatting and a physically grounded image formation model, in: *IEEE International Conference on Robotics and Automation (ICRA)*.
- Yang, L., Kang, B., Huang, Z., Zhao, Z., Xu, X., Feng, J., Zhao, H., 2024. Depth anything v2. *Advances in Neural Information Processing Systems* 37, 21875-21911.
- Yi, J., Bi, Q., Zheng, H., Huang, H., Zhan, H., et al., 2025. AtlantisGS: Underwater sparse-view scene reconstruction via gaussian splatting, in: *ACM International Conference on Multimedia*, pp. 7805-7814.
- Zhang, R., Isola, P., Efros, A.A., Shechtman, E., Wang, O., 2018. The Unreasonable Effectiveness of Deep Features as a Perceptual Metric, in: *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 586-595. doi:10.1109/CVPR.2018.00068.
- Zhang, T., Zhi, W., Meyers, B., Durrant, N., et al., 2025. RecGS: Removing water caustic with recurrent gaussian splatting. *IEEE Robotics and Automation Letters* 10, 668-675. doi:10.1109/LRA.2024.3511418.
- Zhong, J., Li, M., Gruen, A., Schindler, K., Liao, X., Guo, Q., 2025. Cutting-edge 3d reconstruction solutions for underwater coral reef images: A review and comparison. *ISPRS Journal of Photogrammetry and Remote Sensing* 230, 779-803. doi:https://doi.org/10.1016/j.isprsjprs.2025.10.009.
- Zhou, J., Liang, T., Zhang, D., Liu, S., Wang, J., Wu, E.Q., 2025. WaterHE-NeRF: Water-ray matching neural radiance fields for underwater scene reconstruction. *Information Fusion* 115, 102770.